

Fundamentos de Deep Learning

Capítulo 5. Deep Learning

Prof. André Luís Resende Monteiro



Aula 5.1. Introdução ao Deep Learning



Nesta aula

- A relação entre Deep Learning e Redes Neurais Artificiais.

Deep Learning e RNAs

- Durante muitos anos, outras soluções foram preferidas em relação a RNAs
  - Alto custo de hardware necessário.
  - Necessidade de muitos dados.
  - Muito tempo para realizar o treinamento das redes.

Deep Learning e RNAs

- 2012 → acontecimento na história das redes neurais.

Deep Learning e RNAs

- ImageNet → Competição criada em 2010 para avaliar algoritmos de reconhecimentos visuais.









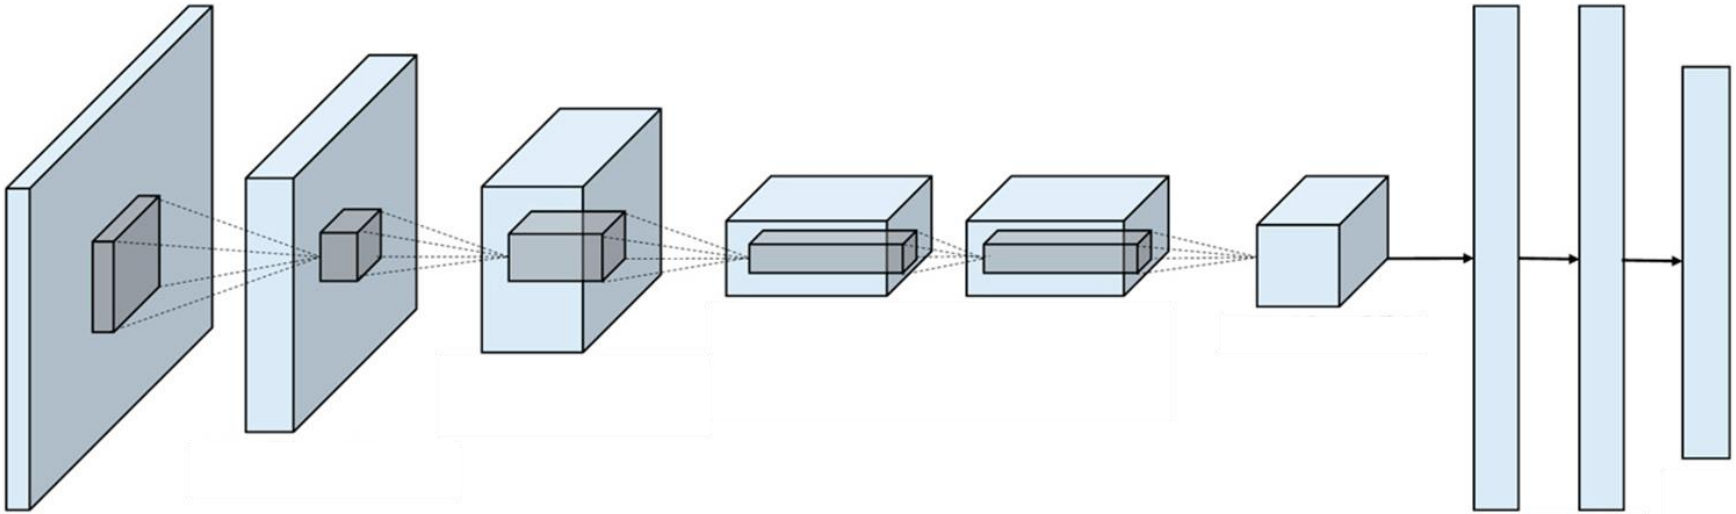
Deep Learning e RNAs

- ImageNet → Competição criada em 2010 para avaliar algoritmos de reconhecimentos visuais
- Até 2011: taxa de erro de 25%
- Em 2012: **taxa de erro de 16%!**



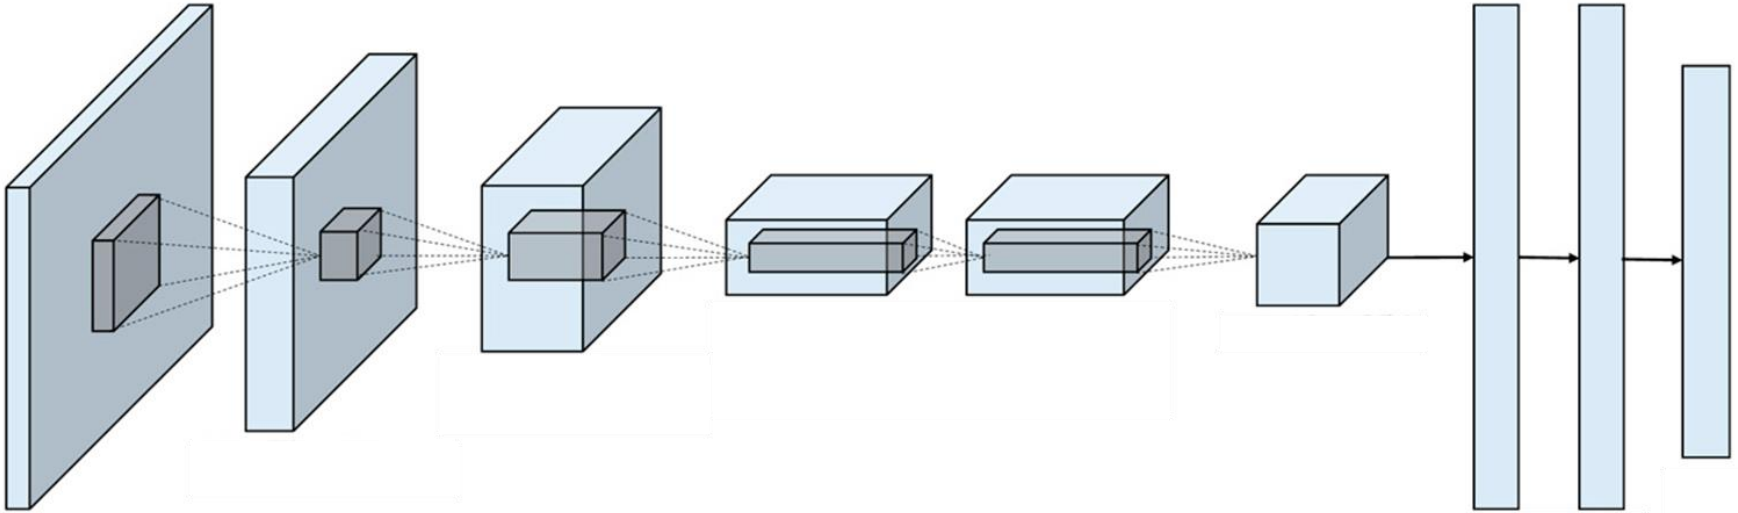
Deep Learning e RNAs

- **Motivo**: uma rede neural especial foi desenvolvida.
- Sete camadas ocultas!
- Otimizada para GPU.



Deep Learning e RNAs

- **AlexNet.**



Deep Learning e RNAs

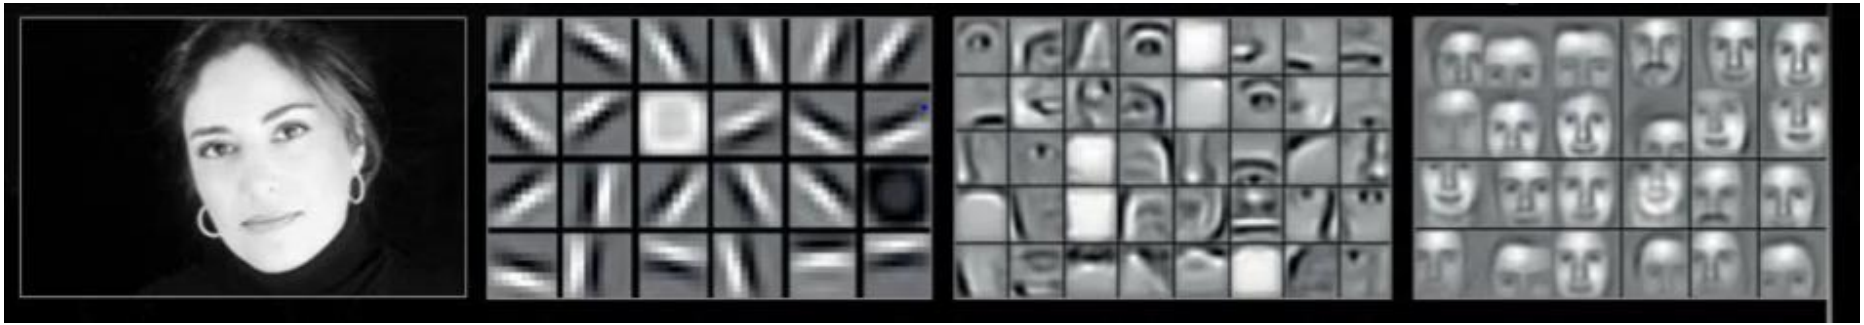
- **Redes Neurais Profundas** → Redes neurais que possuem mais de uma camada oculta.
- **Redes Neurais Rasas (shallow)** → Possuem no máximo uma camada oculta.

Deep Learning e RNAs

- Redes profundas podem modelar relações não lineares complexas.

Deep Learning e RNAs

- As características vão sendo construídas hierarquicamente nas camadas ocultas.



Deep Learning e RNAs

- Pesquisas mostram que redes profundas operam melhor do que redes rasas com o mesmo número de neurônios!

Deep Learning e RNAs

- ImageNet → Competição criada em 2010 para avaliar algoritmos de reconhecimentos visuais.
- Até 2011: taxa de erro de 25%
- Em 2012: **taxa de erro de 16%!**
- Em 2017: **taxa de erro de menos de 5%!**



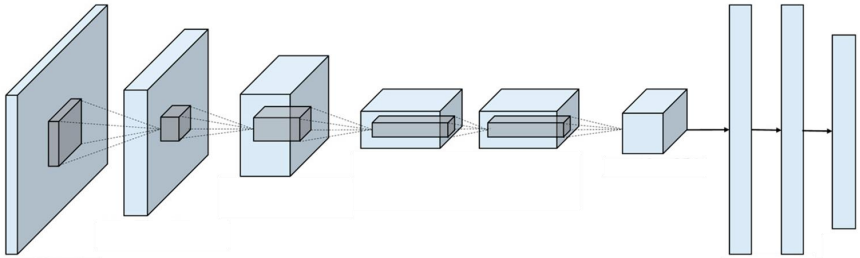


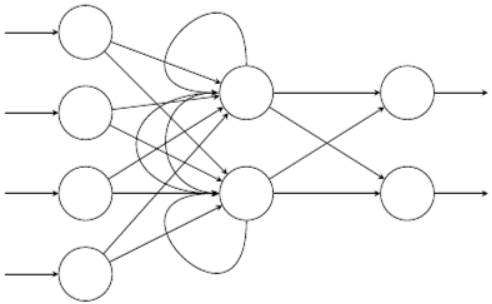


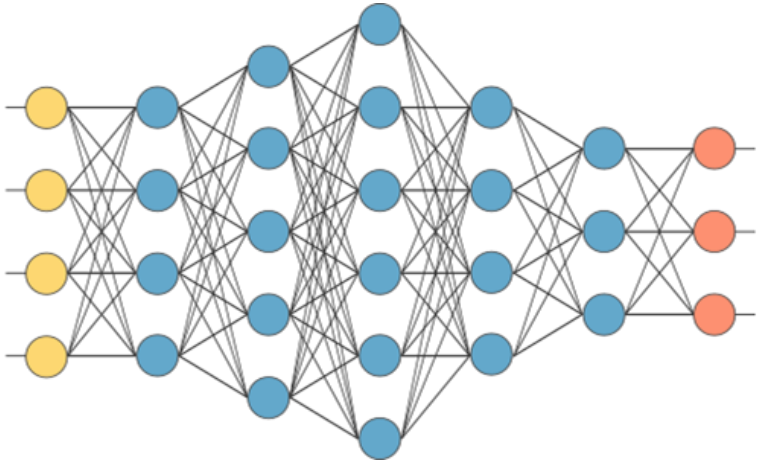


Deep Learning e RNAs

- As redes profundas podem assumir diversas configurações.







Conclusão

- ☑ Redes profundas possuem mais de uma camada oculta.
- ☑ A AlexNet é uma rede profunda que ficou popular ao vencer o campeonato ImageNet, em 2012.
- ☑ Redes profundas conseguem mapear relações não lineares complexas.

Próxima aula

- Redes Neurais Convolucionais (CNN).



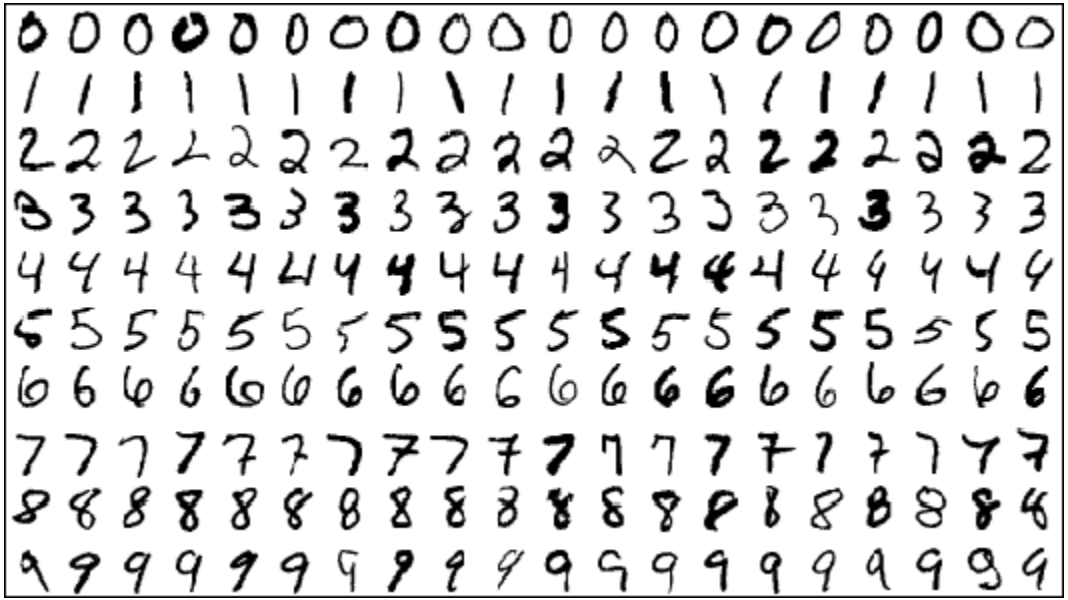
Aula 5.2. Redes Neurais Convolucionais (CNN)



Nesta aula

- Redes Neurais Convolucionais (CNN).

Redes Neurais Convolucionais (CNN)



Redes Neurais Convolucionais (CNN)

- **Problema**: à medida que o número de camadas aumenta, o número de parâmetros também
  - A rede torna-se mais lenta para ser treinada!

Redes Neurais Convolucionais (CNN)

- **Solução (1998)**: usar uma arquitetura diferente de rede, especializada para imagens.

Redes Neurais Convolucionais (CNN)

- **Solução (1998)**: usar uma arquitetura diferente de rede, especializada para imagens
  - Utilizam uma série de convoluções.
  - Chamadas de Redes Neurais Convolucionais (CNN).

Redes Neurais Convolucionais (CNN)

- Ao invés de ligar pixels aos neurônios, liga um conjunto de pixels **(campos receptivos)**.



60	70	0	30
20	2	176	4
90	12	200	0
13	77	89	22

Redes Neurais Convolucionais (CNN)

- Ao invés de ligar pixels aos neurônios, liga um conjunto de pixels **(campos receptivos)**.



20	50	19	80
44	22	100	42
98	15	240	70
12	78	90	22

Redes Neurais Convolucionais (CNN)

- Ao invés de ligar pixels aos neurônios, liga um conjunto de pixels **(campos receptivos)**.



22	51	119	12
40	30	1	90
22	33	12	68
19	77	90	20

Redes Neurais Convolucionais (CNN)

- Cada campo receptivo passa por uma convolução.



22	51	119	12
40	30	1	90
22	33	12	68
19	77	90	20

⊗

0	1	0	0
0	1	0	0
0	1	1	0
0	0	1	0

Redes Neurais Convolucionais (CNN)

- Convolução:

1	0	0	1
1	0	1	0
1	0	0	1
0	1	1	1

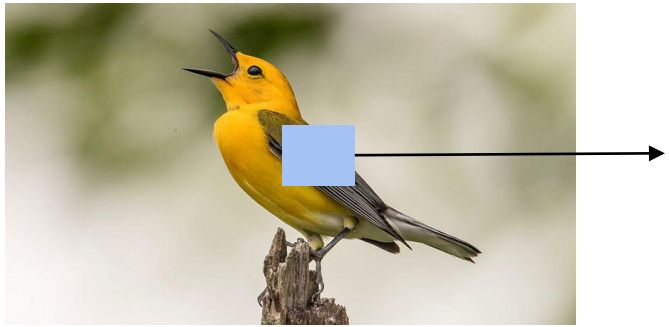


0	1	0	0
0	1	0	0
0	1	1	0
0	0	1	1

= 2

Redes Neurais Convolucionais (CNN)

- Os valores da matriz de convolução são parâmetros calculados pela rede.



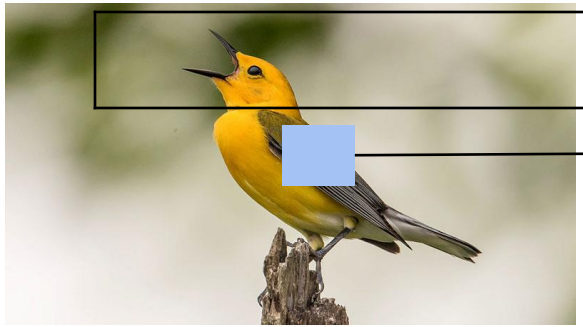
22	51	119	12
40	30	1	90
22	33	12	68
19	77	90	20

⊗

0	1	0	0
0	1	0	0
0	1	1	0
0	0	1	0

Redes Neurais Convolucionais (CNN)

- O resultado da convolução é chamado feature map.



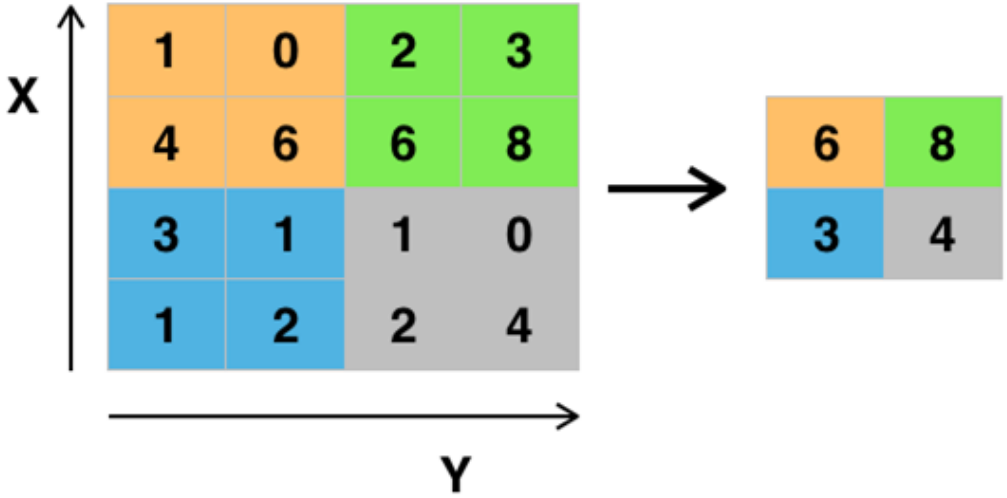
22	51	119	12
40	30	1	90
22	33	12	68
19	77	90	20

⊗

0	1	0	0
0	1	0	0
0	1	1	0
0	0	1	0

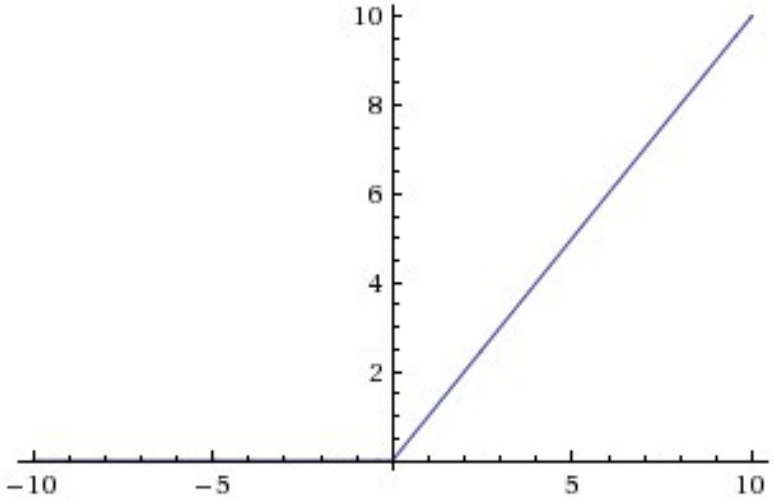
Redes Neurais Convolucionais (CNN)

- Camada de **pooling**: diminui o feature map
  - Normalmente utiliza a função max.
  - Reduz o tamanho da imagem.
  - Torna o reconhecimento invariante à rotação e translação.



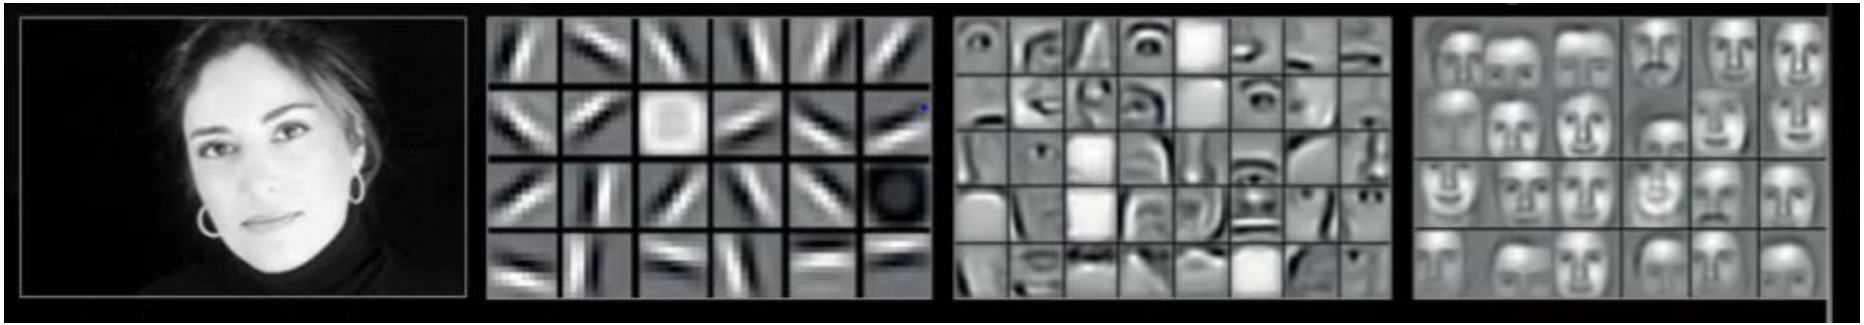
Redes Neurais Convolucionais (CNN)

- Relu como função de ativação.



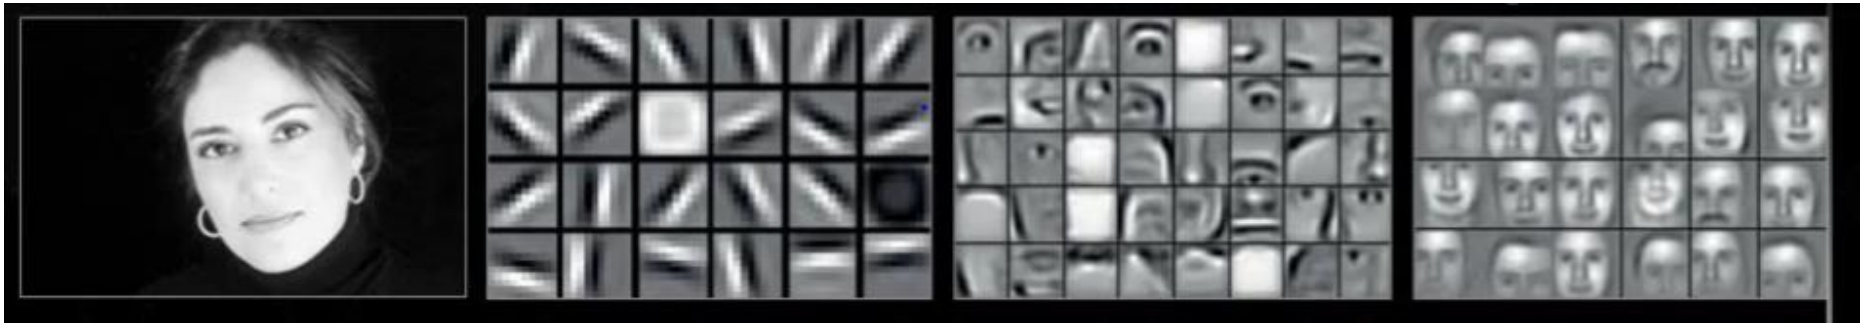
Redes Neurais Convolucionais (CNN)

- Camadas mais avançadas capturam informações mais complexas.



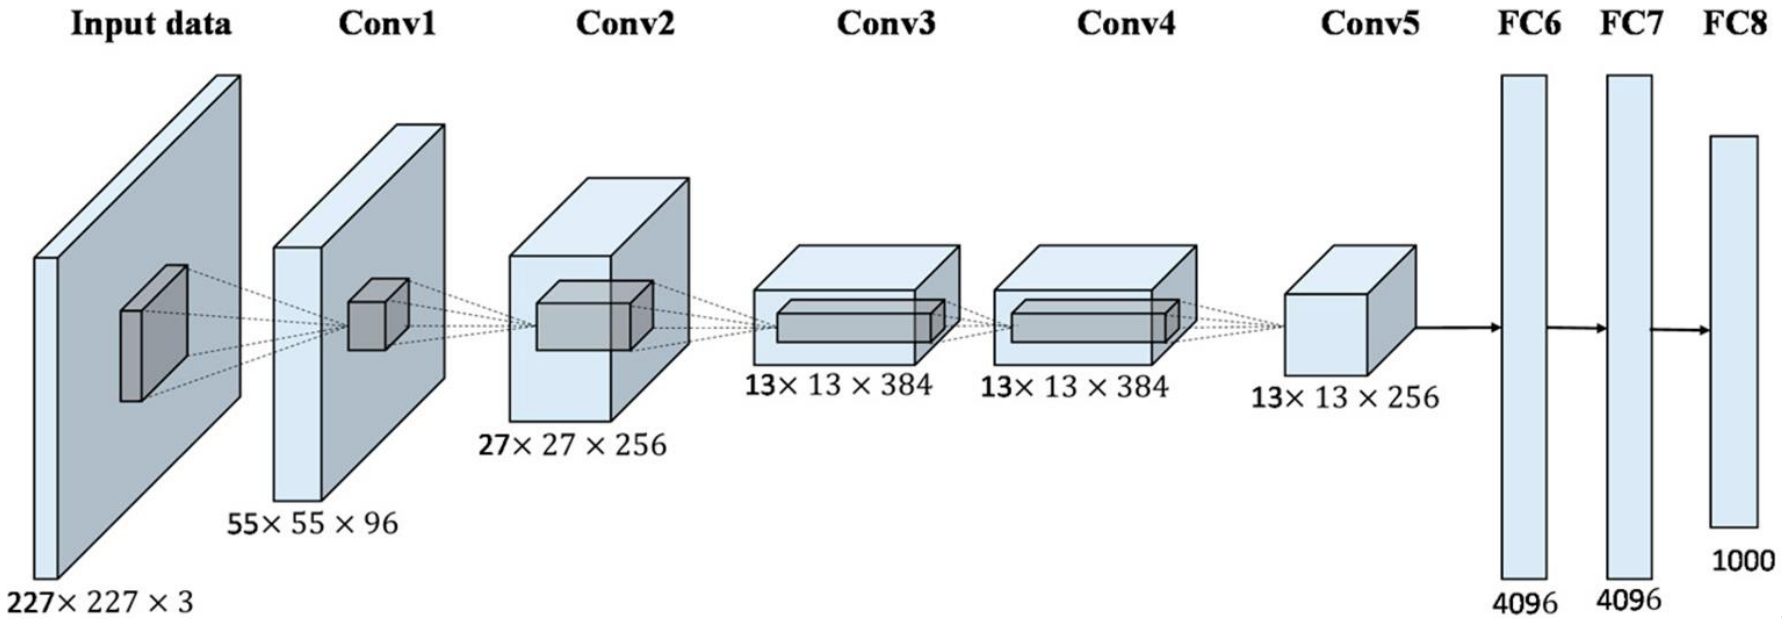
Redes Neurais Convolucionais (CNN)

- **Camadas totalmente conectadas**: agregam as características obtidas da forma tradicional das RNAs.



Redes Neurais Convolucionais (CNN)

- AlexNet



Conclusão

- ☑ Redes Convolucionais (CNNs) utilizam campos receptivos ao invés de ligar cada pixel a um neurônio.
- ☑ Utilizam convoluções para processar a imagem.
- ☑ Utilizam camadas de pooling para reduzir o tamanho e tornar a classificação invariante à rotação e translação.
- ☑ Camadas totalmente conectadas no final agregam as características obtidas.

Próxima aula

- Redes Neurais Recorrentes.



Aula 5.3. Redes Neurais Recorrentes (RNN)



Nesta aula

- Redes Neurais Recorrentes (RNN).

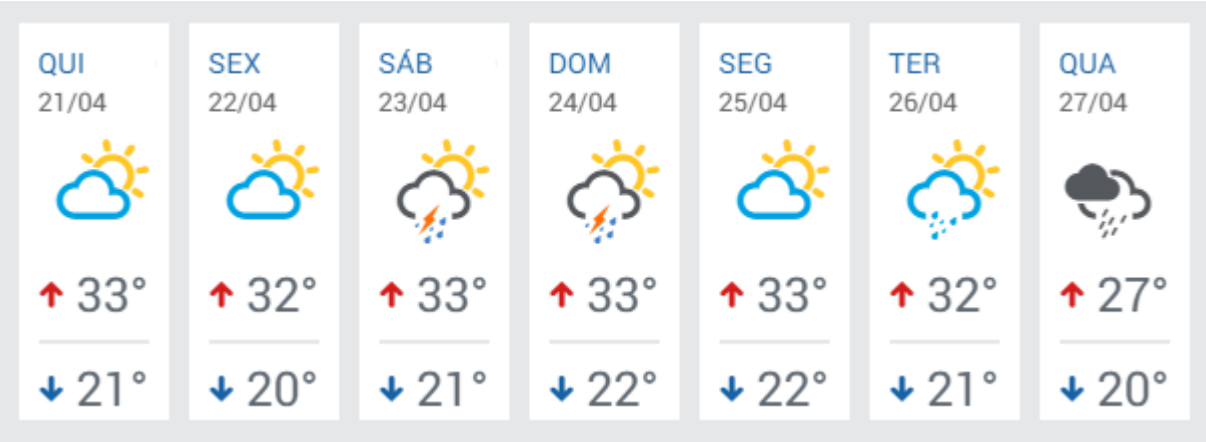
Redes Neurais Recorrentes (RNN) - Exemplos



Redes Neurais Recorrentes (RNN) - Exemplos



Redes Neurais Recorrentes (RNN) - Exemplos

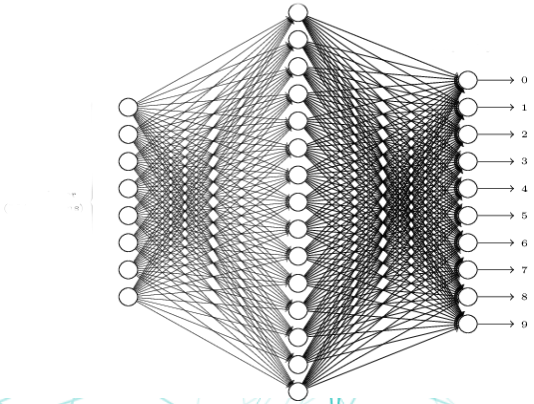


Redes Neurais Recorrentes (RNN) - Exemplos

- **Tradução:** “Deep Learning”.

Redes Neurais Recorrentes (RNN)

- **Problema:** todos esses exemplos possuem uma sequência!
- Todos dependem do resultado anterior para o cálculo do próximo resultado.
- Redes do tipo feed-forward não possuem essa possibilidade.



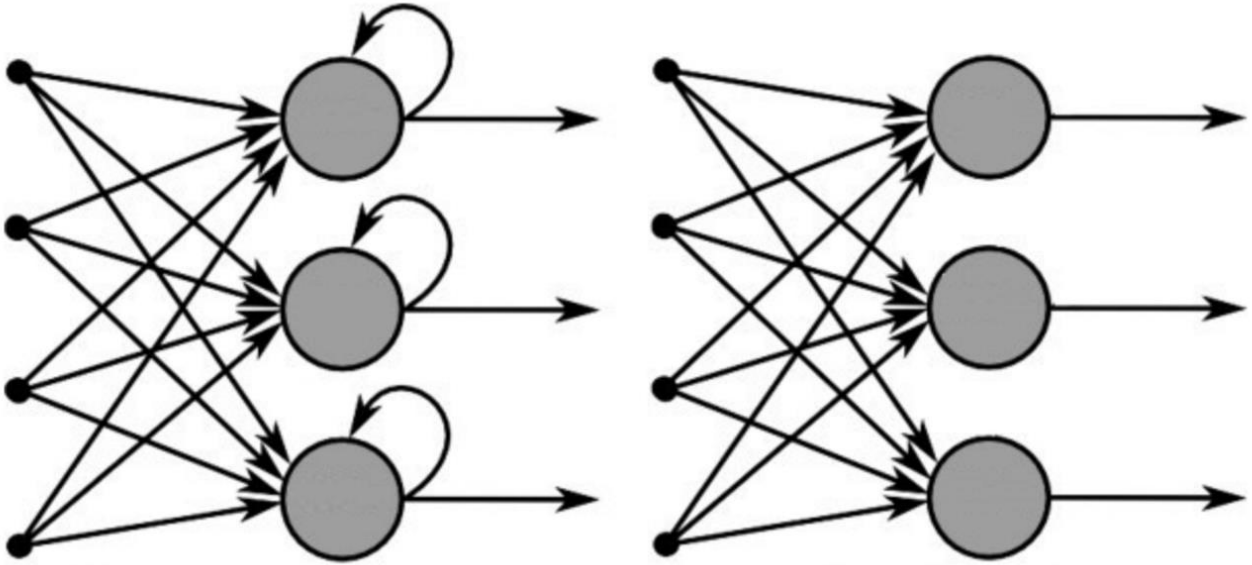
Redes Neurais Recorrentes (RNN)

- **Solução:** uma rede em que resultados anteriores influenciem os próximos resultados!

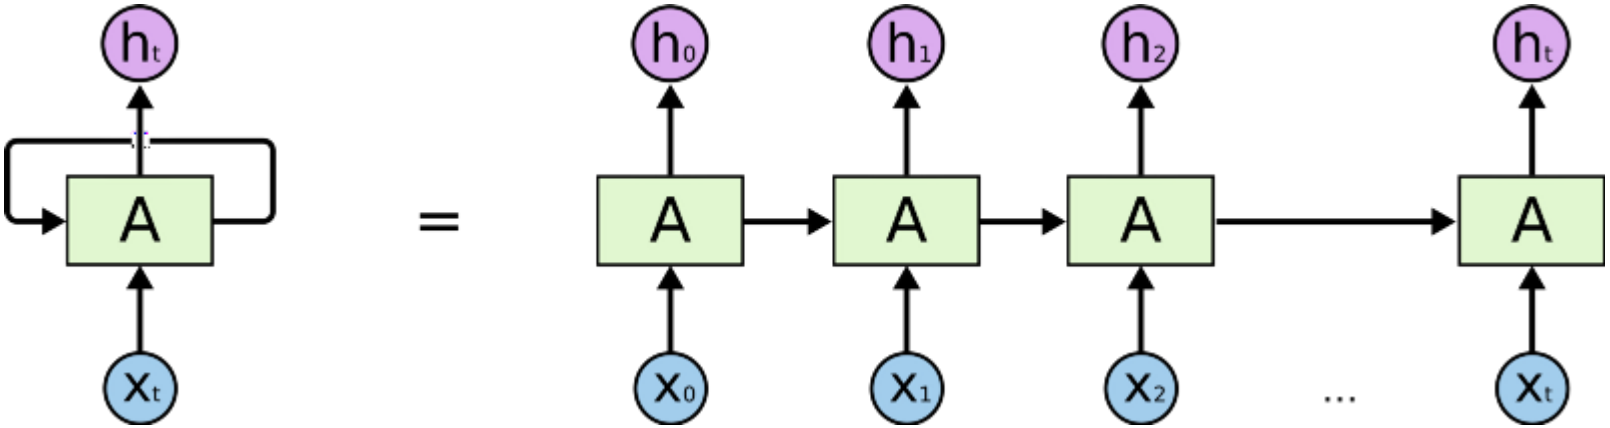
Redes Neurais Recorrentes (RNN)

- **Redes Neurais Recorrentes (RNN):** rede neural que possui uma memória, de forma que resultados anteriores influenciem os próximos resultados.

Redes Neurais Recorrentes (RNN)



Redes Neurais Recorrentes (RNN)



Redes Neurais Recorrentes (RNN)

- Criadas na década de 1980.
- Usada para problemas em que existe uma sequência.
- Utiliza o algoritmo de Retropropagação Através do Tempo (BPTT) para realizar o ajuste dos parâmetros.

Conclusão

- ☑ Redes Neurais Recorrentes (RNN) são utilizadas quando existe uma sequência.
- ☑ Em RNNs, um resultado de uma unidade de tempo é propagado e utilizado na unidade de tempo seguinte.
- ☑ Utilizam o algoritmo de Retropropagação Através do Tempo (BPTT) para realizar a definição dos parâmetros.

Próxima aula

- Redes do tipo Long-short term memory (LSTM).



Aula 5.4. Redes do tipo Long-short term memory (LSTM)

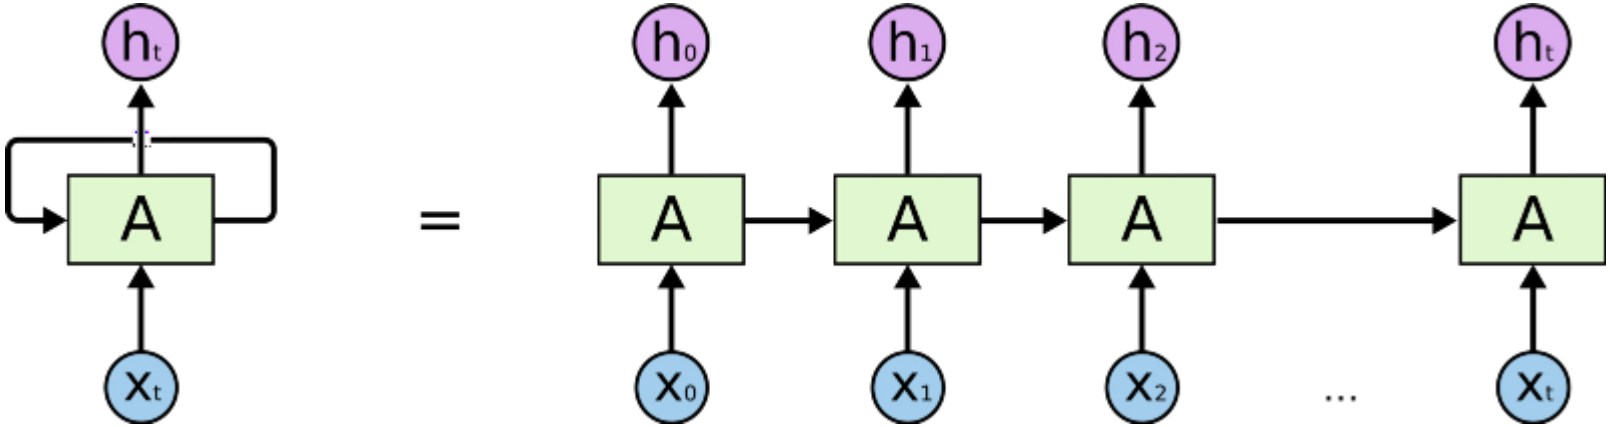


Nesta aula

- O problema das redes RNN.
- Redes Long-short term memory (LSTM).
- Redes Gated recurrent unit (GRU).

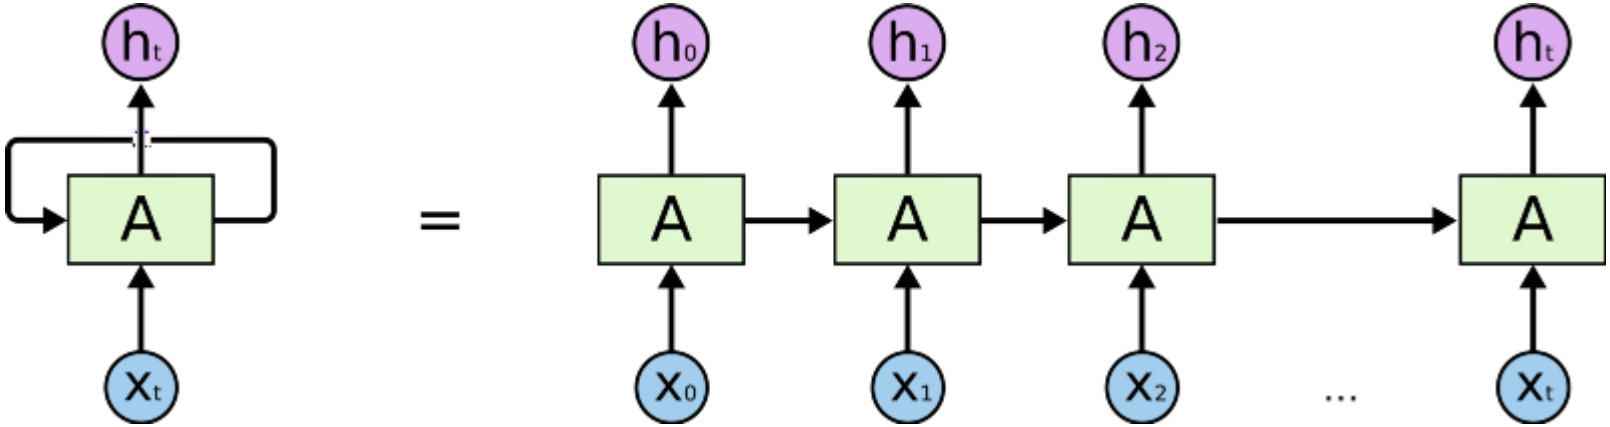
O problema das RNN

- **Exemplo:** A grama é verde.



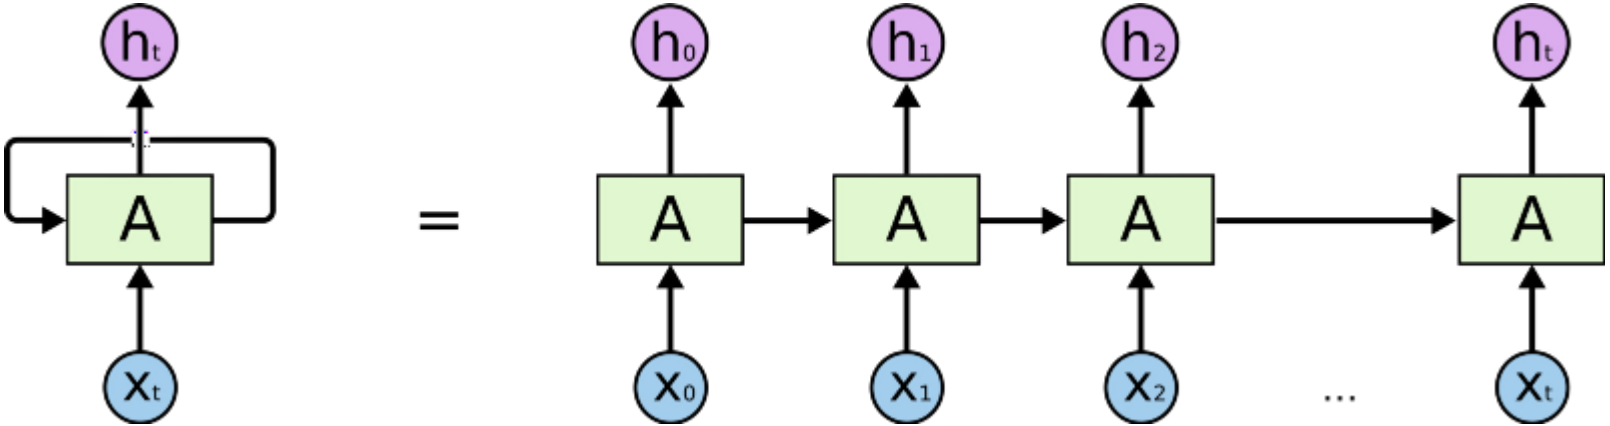
O problema das RNN

- **Exemplo:** Eu sou francês … (200 palavras), logo eu falo francês.



O problema das RNN

- **Problema:** desaparecimento do gradiente → o gradiente das primeiras sequências tendem a ser pequenos.



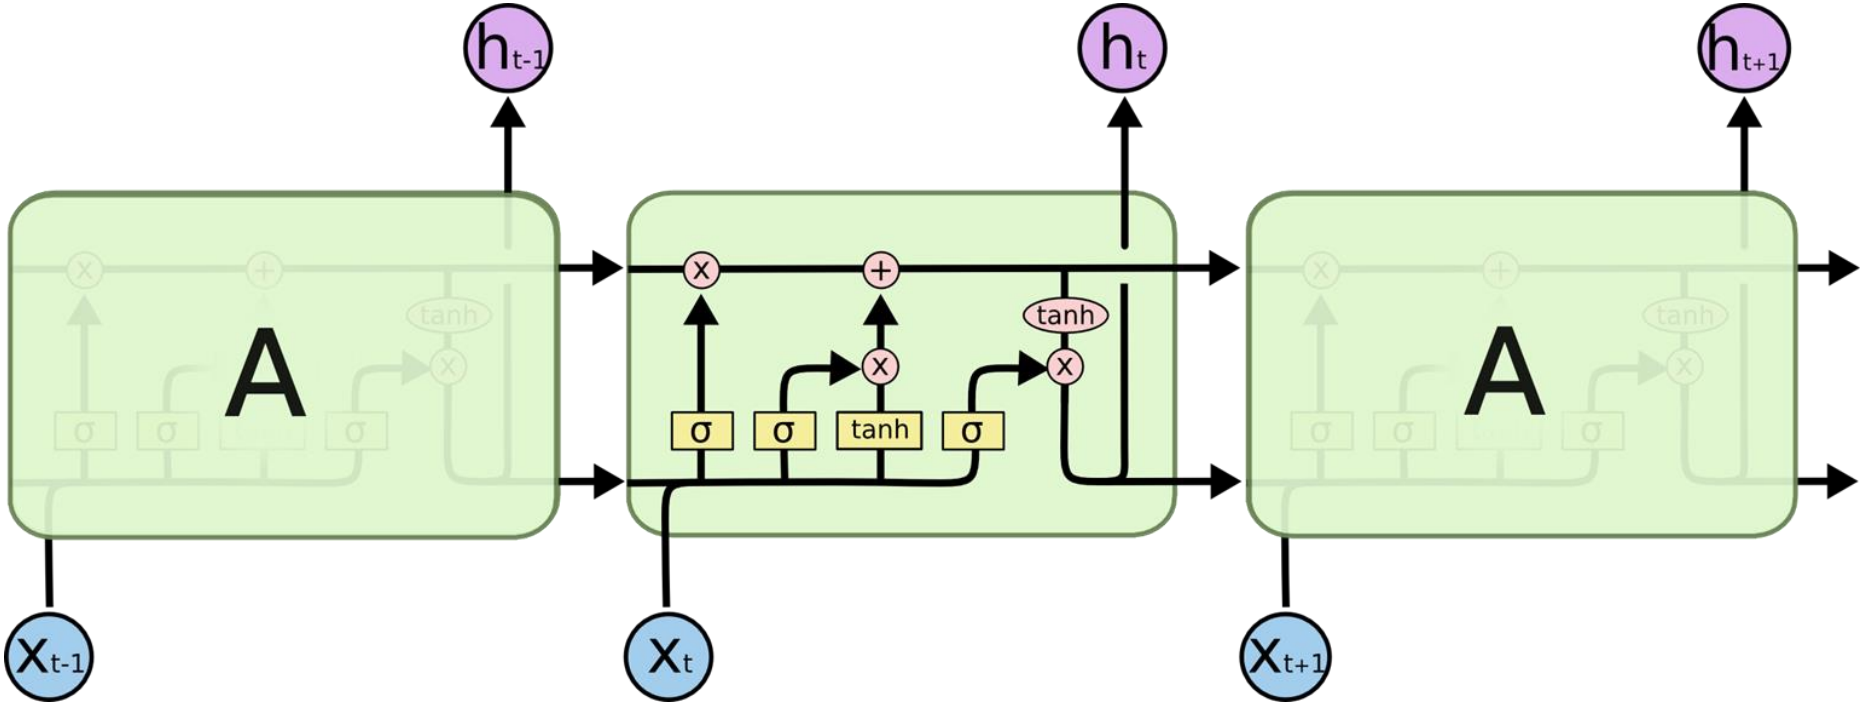
Redes Long-short term memory (LSTM)

- **Solução:** criação de uma rede que consiga controlar melhor as informações do passado.
- Long-short term memory (LSTM).

Redes Long-short term memory (LSTM)

- Altera a estrutura típica do neurônio das redes RNN (somatório e função de ativação).
- Três “portões” (esquecimento, entrada e saída), cada um funcionando como uma rede neural.

Redes Long-short term memory (LSTM)



Redes Long-short term memory (LSTM)

- Redes mais complexas.
- Possuem mais parâmetros.
- Maior tempo para treinamento.

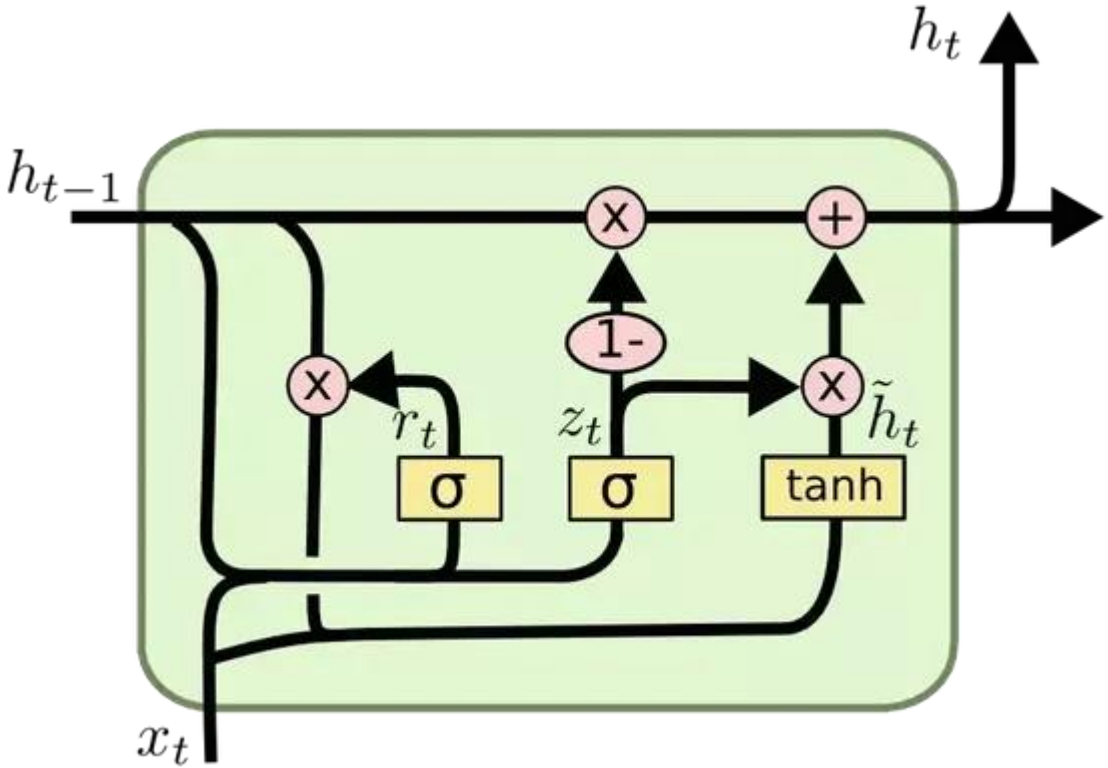
Redes Long-short term memory (LSTM)

- **Portão de esquecimento (forget gate)** → Indica qual informação do passado deve ser esquecida.
- **Portão de entrada (input gate)** → Indica qual informação deve ser incluída no fluxo de informações.
- **Portão de saída (output gate)** → Indica qual informação deve ser propagada para frente.

Redes Gated Recurrent Unit (GRU)

- Tipo especial de LSTM.
- Menos tempo para treinamento.
- Necessita de menos dados para ser eficiente.

Redes Gated Recurrent Unit (GRU)



Redes Gated Recurrent Unit (GRU)

- **Portão de atualização** → Define quais informações passadas devem ser propagadas.
- **Portão de reset** → Define quais informações passadas devem ser esquecidas.

Conclusão

- ☑ As RNN possuem o problema do desaparecimento do gradiente.
- ☑ Redes LSTM e GRU são utilizadas para solucionar esse problema.
- ☑ LSTM e GRU conseguem controlar quais informações passadas devem ser preservadas e quais devem ser esquecidas.
- ☑ LSTM possui três estruturas chamadas portões: esquecimento, entrada e saída.
- ☑ GRU possui duas estruturas chamadas portões: atualização e reset.
- ☑ GRU leva menos tempo para ser treinada do que o LSTM.

Próxima aula

- Redes Neurais Recursivas.



Aula 5.5. Redes Neurais Recursivas



Nesta aula

- Redes Neurais Recursivas.

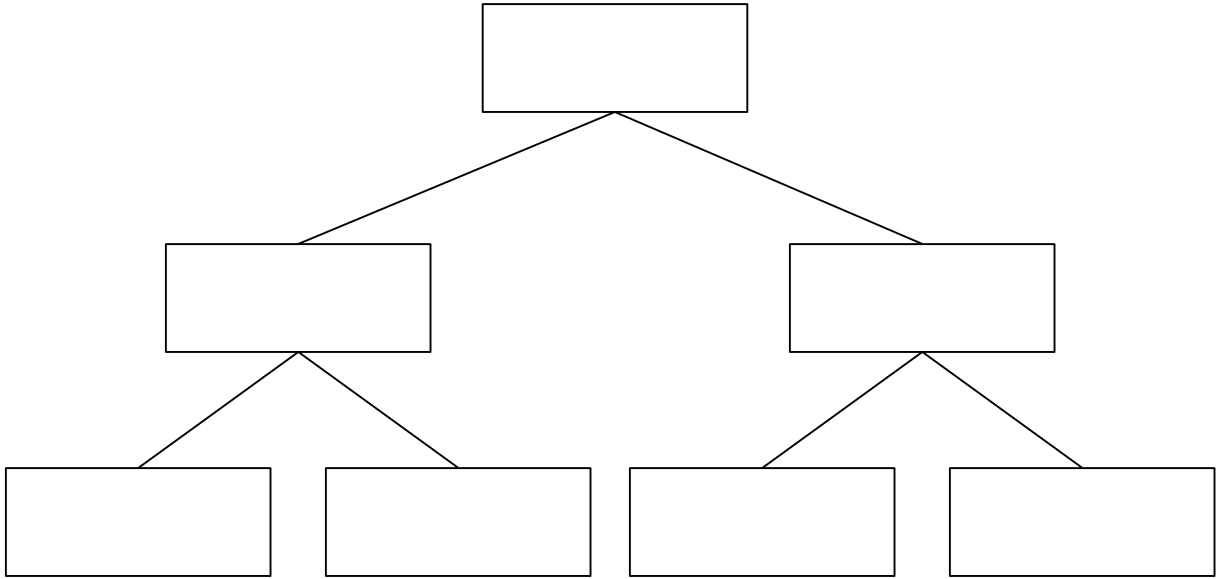
Redes Neurais Recursivas

- Como identificar que duas sentenças possuem a mesma semântica?
  - O homem de skate caiu.
  - O skatista foi ao chão.
- A semântica de uma frase é construída de forma hierárquica.

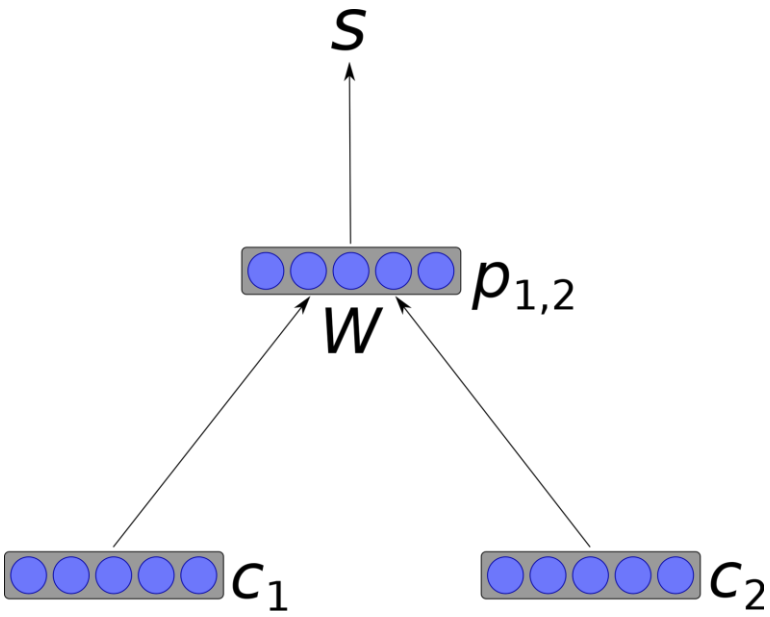
Redes Neurais Recursivas

- **Sugestão**: criação de uma rede que analise recursivamente pares de palavras.
- Redes Neurais Recursivas (2011).

Redes Neurais Recursivas



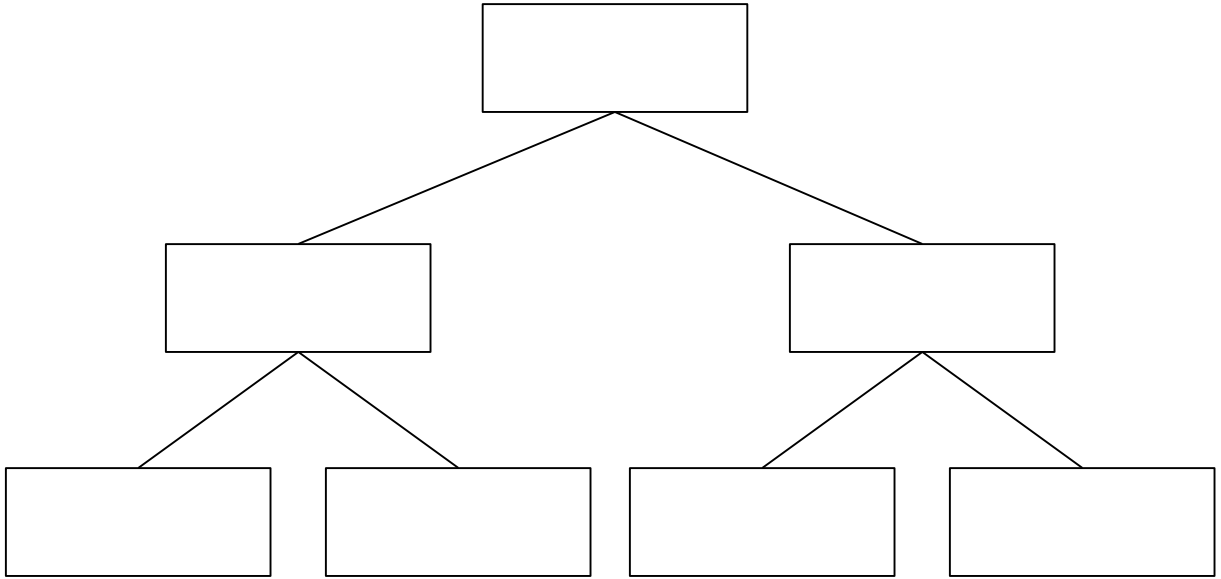
Redes Neurais Recursivas



$$S = W_{score} * p$$

$$p = f(W[c_1; c_2] + b)$$

Redes Neurais Recursivas

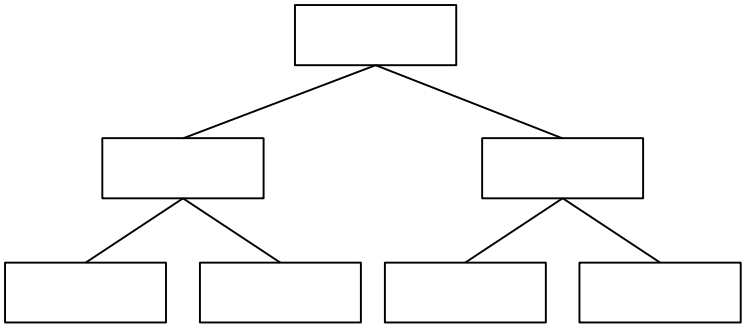


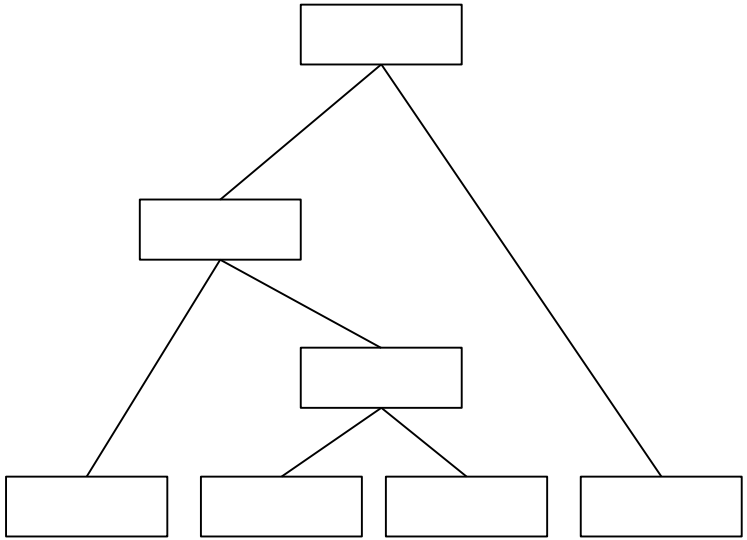
$$S = W_{score} * p$$

$$p = f(W[c_1; c_2] + b)$$

Redes Neurais Recursivas

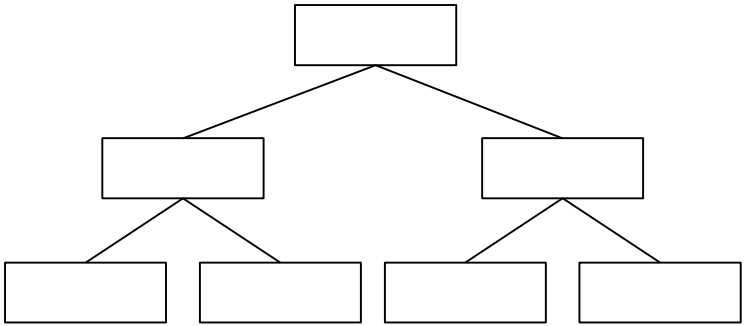
- **Problema**: uma mesma frase pode possuir várias representações.
- Como definir a melhor?

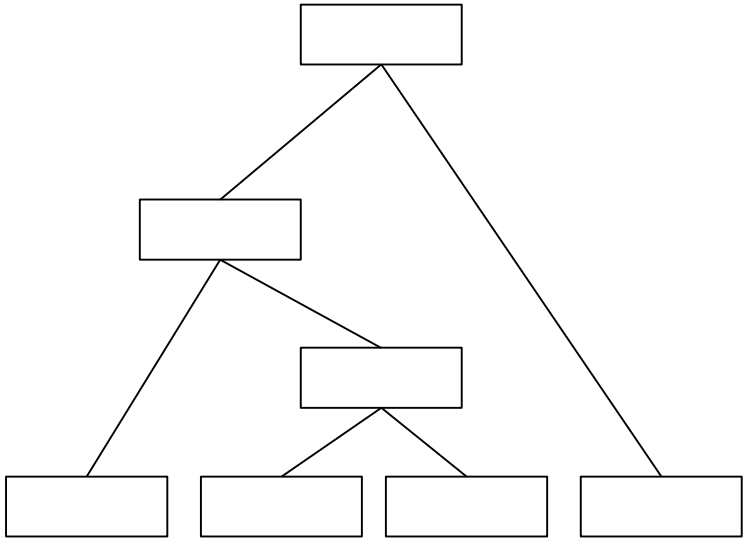




Redes Neurais Recursivas

- **Solução**: somar os resultados (scores) de cada par.





Redes Neurais Recursivas

- Aplicações:
  - Processamento de linguagens naturais
    - Análise de sentimentos.
- Uma variação do algoritmo de retropropagação é utilizada, conhecida como BPTS.

Conclusão

- ☑ Redes neurais recursivas são aplicadas a problemas que possuem uma hierarquia, com o processamento de linguagens naturais.
- ☑ Podem ser usadas para identificar duas frases com a mesma semântica.
- ☑ Realiza a união de pares de frases, calculando um resultado para cada.
- ☑ Os pesos são calculados através de uma variação do algoritmo de retropropagação.

Próxima aula

- Redes Neurais do tipo GAN.



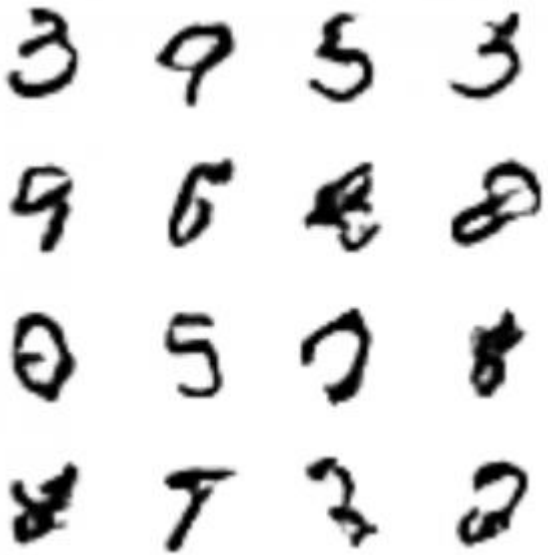
Aula 5.6. Redes Neurais do tipo GAN

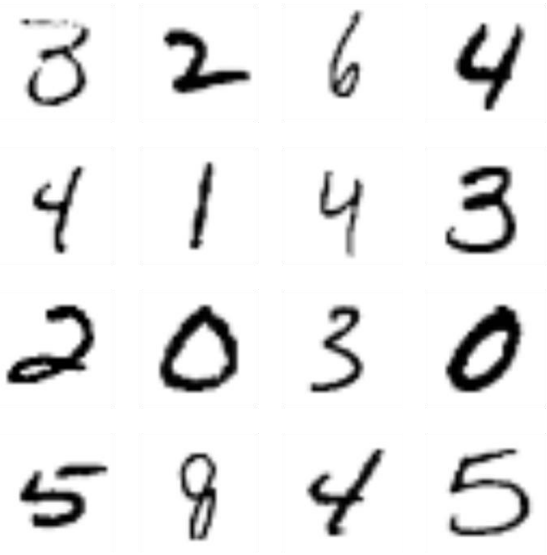


Nesta aula

- Redes Neurais do tipo GAN.

Redes Neurais do tipo GAN





Redes Neurais do tipo GAN

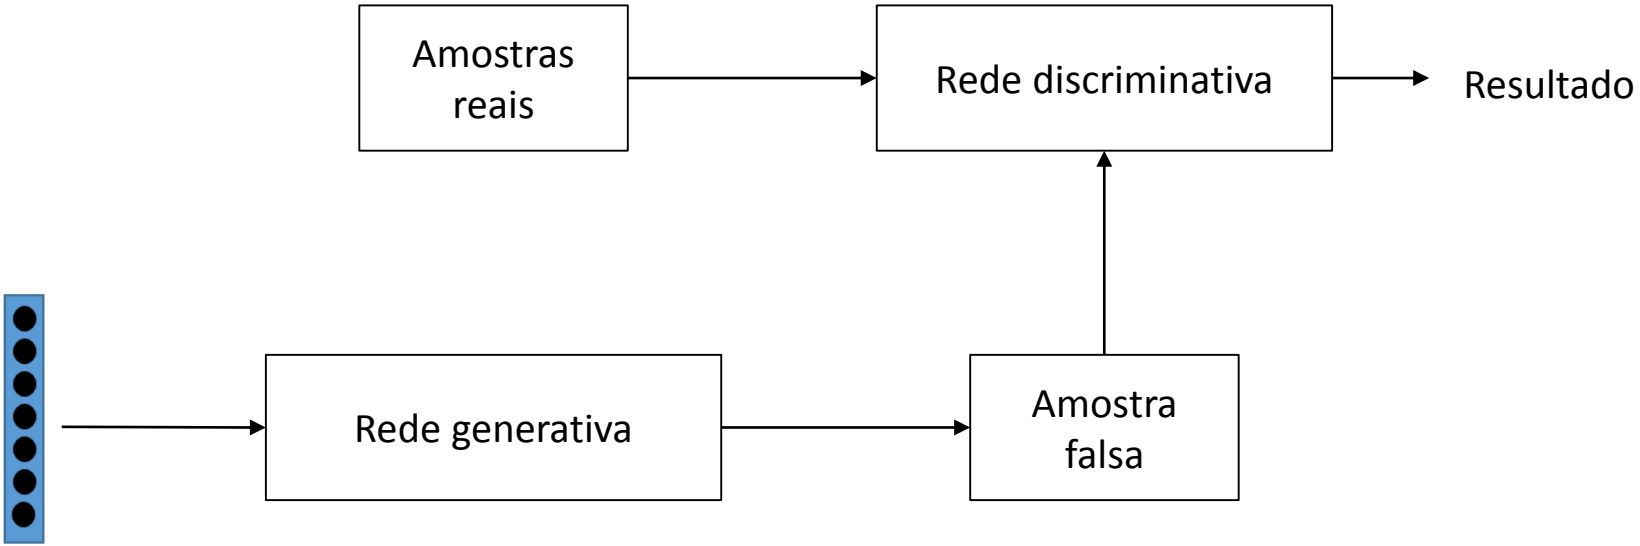
- Y = resultado
- X = vetor que representa o dado
- **Algoritmos discriminativos** → P (Y / X)
- **Algoritmos generativos** → P (X / Y)

Redes Neurais do tipo GAN

- **Redes Generative Adversarial Networks (GAN)**: Redes com o objetivo de copiar distribuições de dados.
- Propostas em 2014.
- Utilizam duas redes: uma generativa e outra discriminativa.

Redes Neurais do tipo GAN

- Rede discriminativa (convolucional) e generativa (deconvolucional).



Redes Neurais do tipo GAN

- Aplicações: colorização automática.



Redes Neurais do tipo GAN

- Aplicações: geração de imagens a partir de bordas.



Redes Neurais do tipo GAN

- Aplicações: reconstrução de imagens.



Conclusão

- ☑ Algoritmos discriminativos tentam discriminar amostras.
- ☑ Algoritmos generativos tentam gerar amostras de uma determinada distribuição.
- ☑ Redes do tipo GAN têm como objetivo gerar dados.
- ☑ Redes do tipo GAN utilizam uma rede generativa e outra adaptativa.

Próxima aula

- Overfitting (sobreajuste).



Aula 5.7. Overfitting

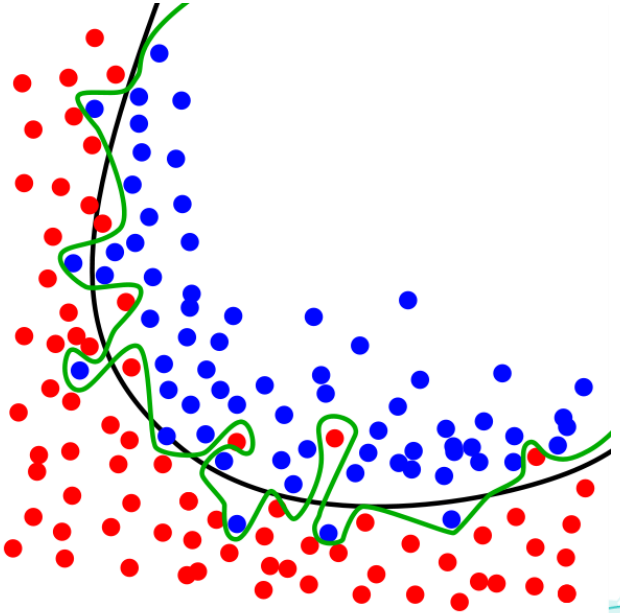


Nesta aula

- Overfitting (sobreajuste).

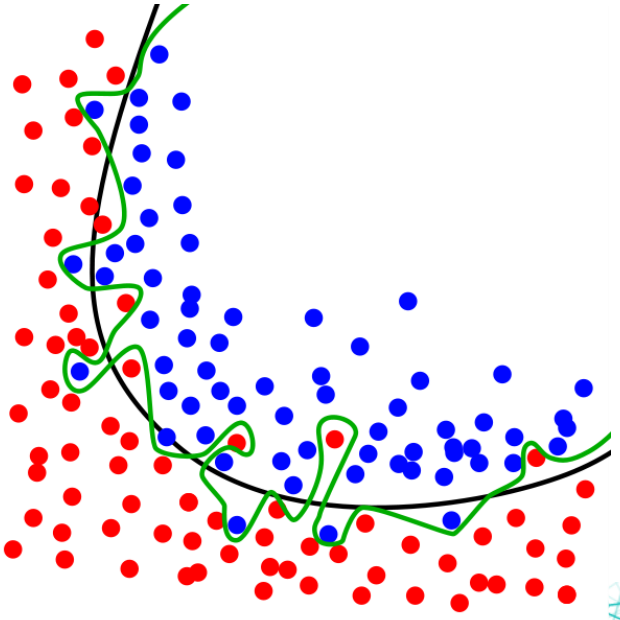
Overfitting (sobreajuste)

- Um problema pode ter várias soluções.
- **Modelo** → Conjunto de parâmetros que definem uma solução.



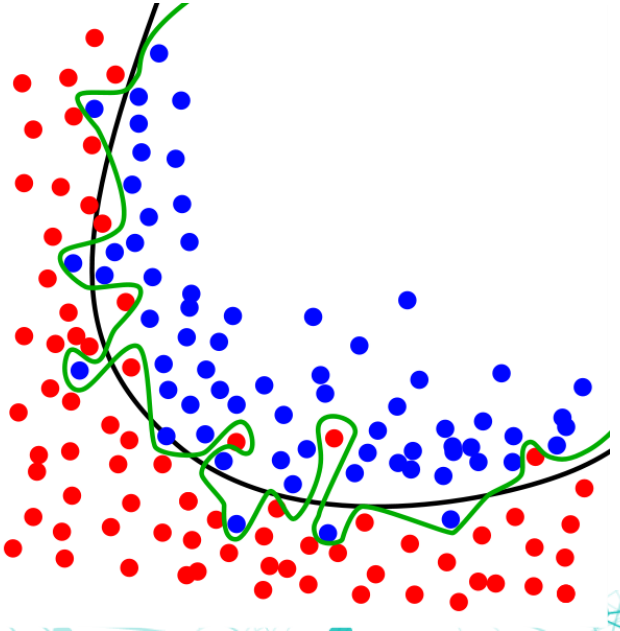
Overfitting (sobreajuste)

- Modelo verde → Classifica corretamente **todas** as amostras.
- Modelo preto → Classifica corretamente **a maioria** das amostras.



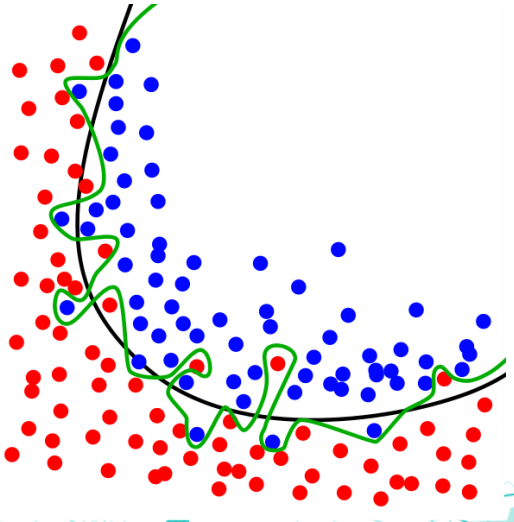
Overfitting (sobreajuste)

- Qual dos modelos é o melhor?
- O que vai acontecer com novos dados desconhecidos?



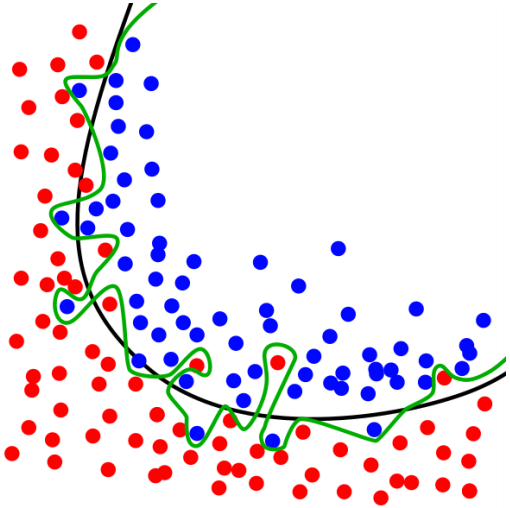
Overfitting (sobreajuste)

- **Generalização** → Capacidade de classificar corretamente amostras que não se conhecem.
- **Complexidade** → Modelos muito complexos tendem a não generalizar bem.



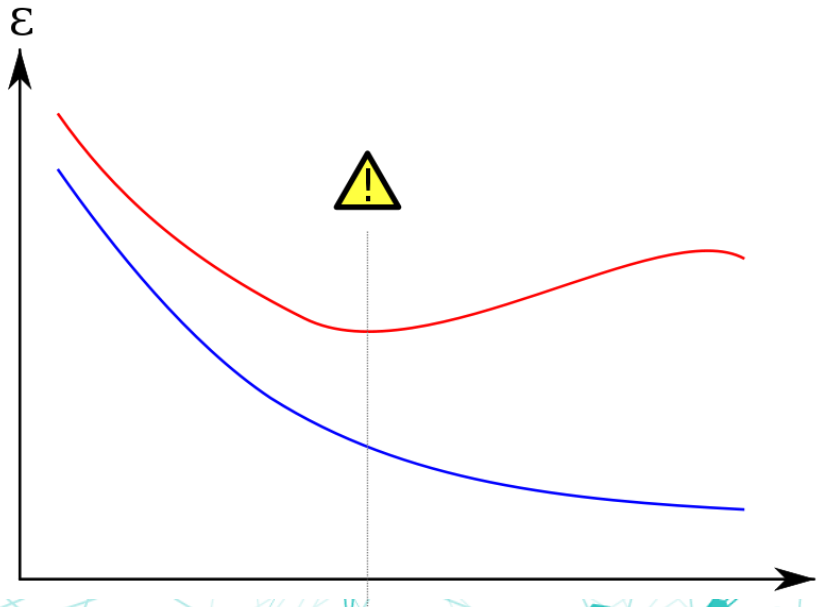
Overfitting (sobreajuste)

- Modelos complexos tendem a **memorizar** os dados de treino ao invés de obter relações.



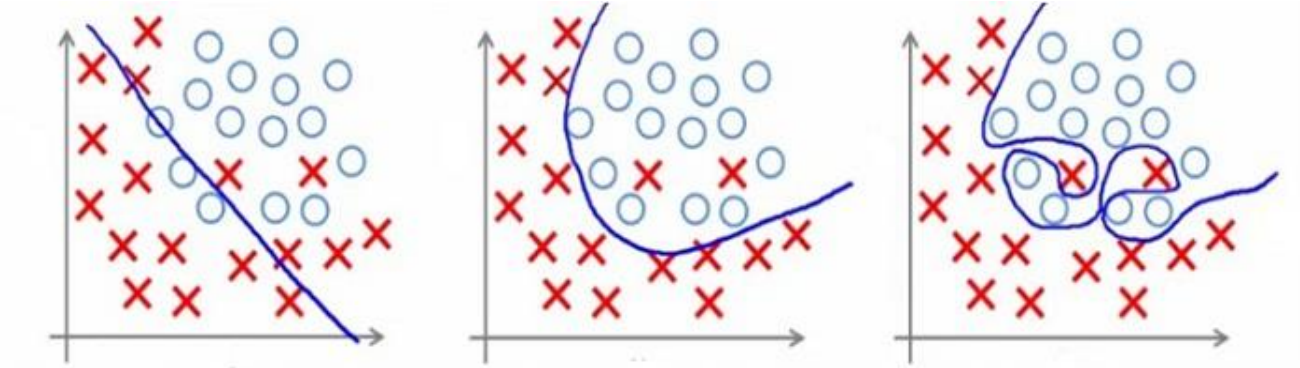
Overfitting (sobreajuste)

- **Overfitting** → Ocorre quando um modelo se adapta muito bem ao conjunto de treino, mas falha ao prever dados não conhecidos.



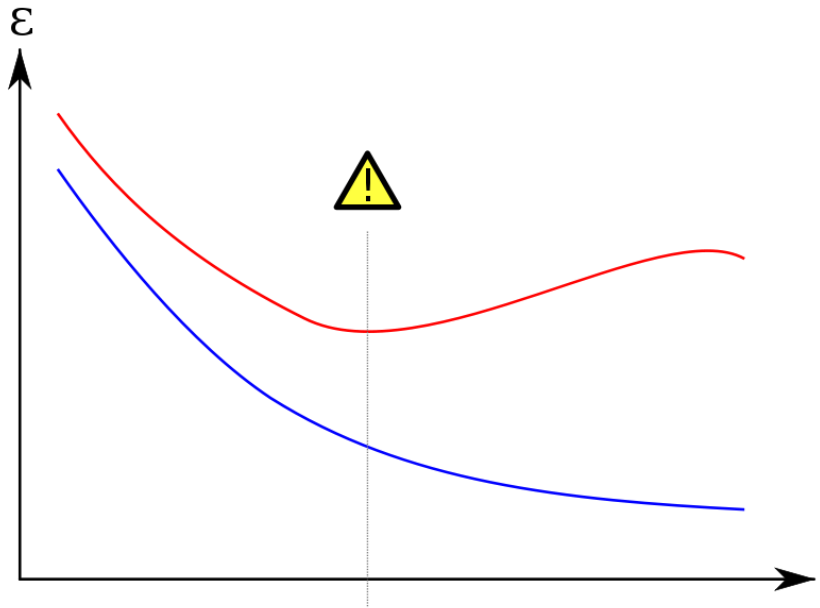
Overfitting (sobreajuste)

- **Subajuste** → Modelo não consegue se adaptar bem ao conjunto de treino.



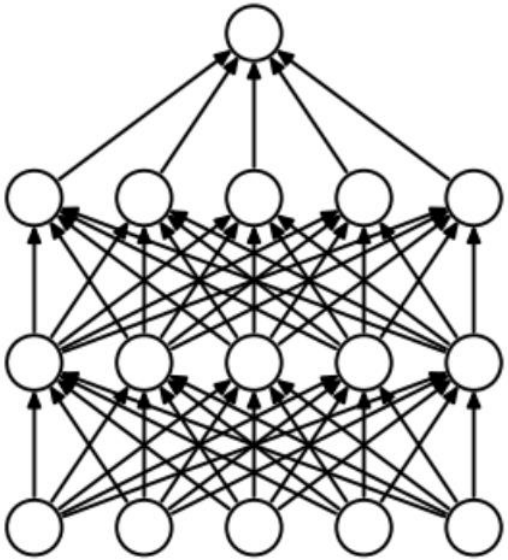
Soluções para o Overfitting (sobreajuste)

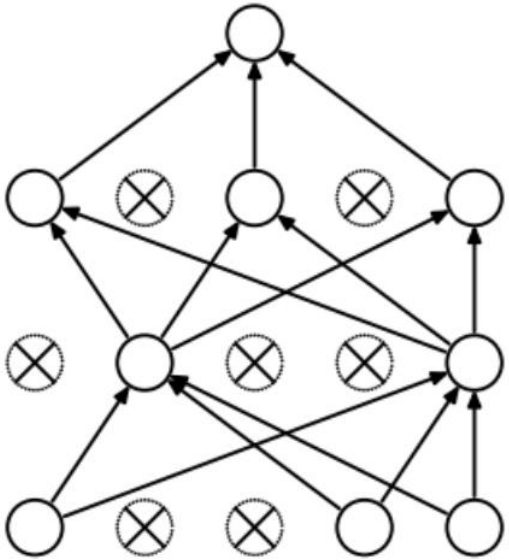
- **Parada antecipada** → Interrupção do desenvolvimento do modelo quando se identifica que o overfitting está ocorrendo.



Soluções para o Overfitting (sobreajuste)

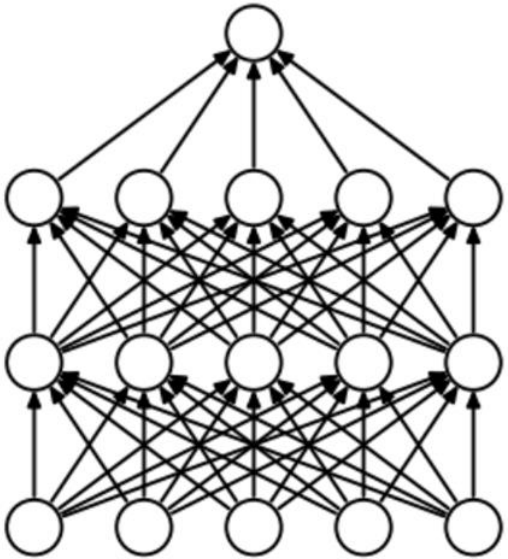
- **Dropout** → Consiste em desabilitar aleatoriamente alguns neurônios durante o treino, de forma a forçar novas sinápses.





Soluções para o Overfitting (sobreajuste)

- **Regularização** → Adaptar a função de custo para penalizar modelos complexos.
- **Decaimento dos pesos** → Penaliza modelos com pesos muito altos.



$$L(W) = \frac{1}{2}\sum_{i}(\sigma(W^T X^{(i)}) - y^{(i)})^2 + ||W||$$

Conclusão

- ☑ Overfitting, ou sobreajuste, está relacionado à incapacidade de um modelo classificar bem dados não conhecidos.
- ☑ Modelos complexos tendem a sofrer de overfitting.
- ☑ Generalização é a capacidade de um modelo se adaptar bem aos dados não conhecidos.
- ☑ Modelos em overfitting tendem a memorizar os dados ao invés de descobrir as relações entre eles.
- ☑ Parada antecipada, dropout e regularização são utilizados para evitar o overfitting.
- ☑ Decaimento dos pesos é uma forma de se implementar a refularização.

Próxima aula

- Métodos de avaliação de modelos.



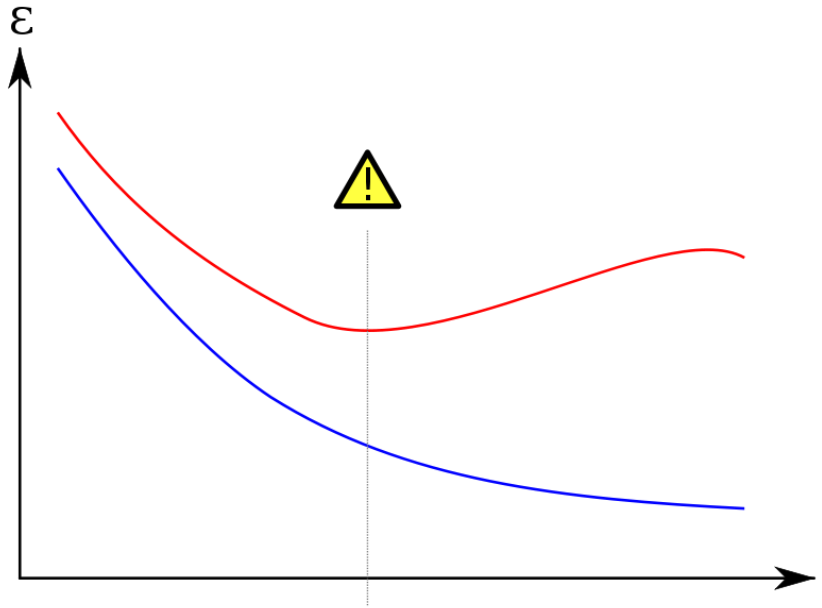
Aula 5.8. Métodos de avaliação de modelos

Nesta aula

- Métodos de avaliação de modelos.

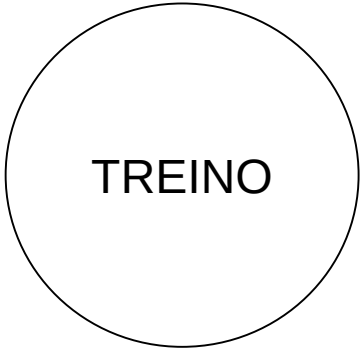
Métodos de avaliação de modelos

- Como estimar o erro nos dados que não conhecemos?



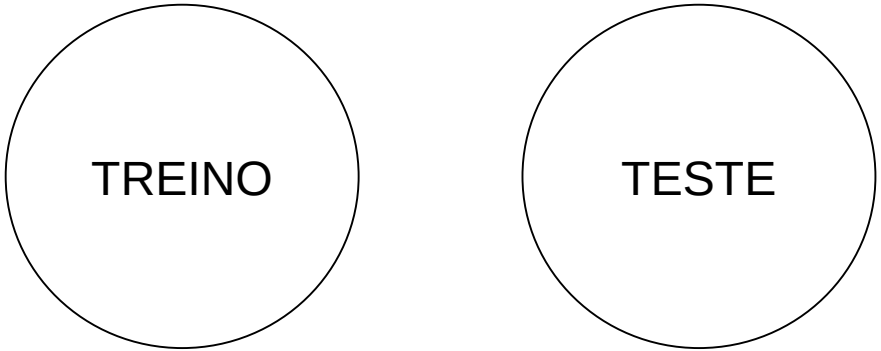
Métodos de avaliação de modelos

- Apenas conjunto de treino
  - Útil quando se tem acesso a TODOS os dados.
  - Interessado em descrever o problema, e não em realizar novas predições.
  - Pode produzir overfitting!



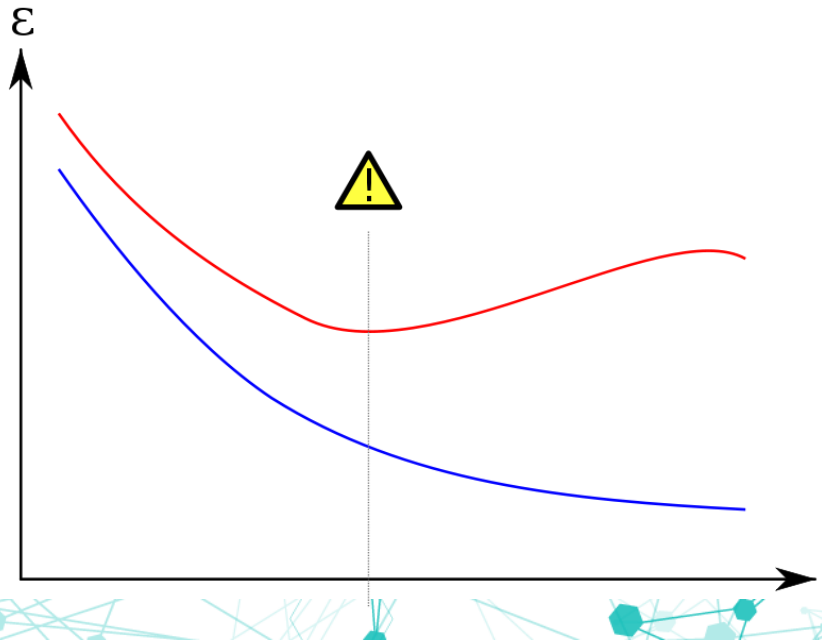
Métodos de avaliação de modelos

- Dividir as amostras em dois conjuntos
  - Conjunto de treino → utilizado para definir os parâmetros do modelo.
  - Conjunto de teste → utilizado para obter as métricas do modelo.
  - Normalmente utiliza uma porcentagem (70%-30%).



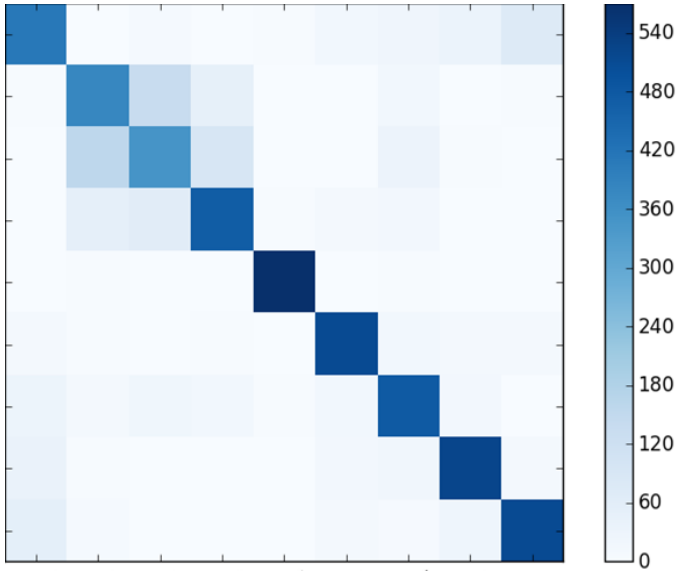
Métodos de avaliação de modelos

- Com a divisão entre treino e teste, é possível simular o erro das amostras desconhecidas.



Métodos de avaliação de modelos

- **Matriz de confusão** → permite visualizar a performance do modelo.
- O ideal é que apenas a diagonal principal seja preenchida.



Métodos de avaliação de modelos

- **Problemas binários:**
  - Falso positivo → uma amostra como negativa é classificada como positiva.
  - Falso negativo → uma amostra positiva é classificada como negativa.

Métodos de avaliação de modelos

- É melhor ter um número maior de falsos positivos ou falsos negativos?
  - Biometria para acessar um caixa eletrônico.
  - Avaliação de um tumor em um exame.

Conclusão

- ☑ Utilizar todas as amostras como conjunto de treino é útil para explicar o modelo.
- ☑ Dividir o conjunto de amostras em treino e teste é útil para evitar overfitting.
- ☑ Divisão em treino e teste é uma forma de simular a existência de amostras desconhecidas.
- ☑ Uma matriz de confusão é útil para visualizar a performance do modelo.
- ☑ Em uma matriz de confusão, idealmente apenas a diagonal principal deve ser preenchida.
- ☑ A escolha por falsos positivos ou falsos negativos depende do problema.

Próxima aula

- Definição de hiperparâmetros da rede.



Aula 5.9. Hiperparâmetros da rede



Nesta aula

- Hiperparâmetros de uma rede.
- Mecanismos de definição.

Definição dos hiperparâmetros de uma rede

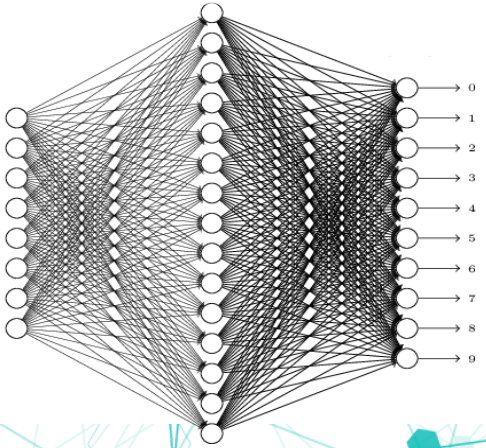
- Objetivo do treinamento de uma rede → definição dos parâmetros (pesos e bias).

Definição dos hiperparâmetros de uma rede

- Há outra classe de parâmetros definida antes do processo de treinamento → **hiperparâmetros**
  - Correspondem a parâmetros de alto nível do modelo.

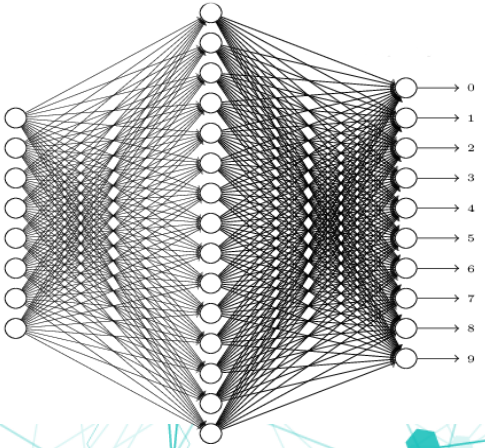
Definição dos hiperparâmetros de uma rede

- Há outra classe de parâmetros definida antes do processo de treinamento → **hiperparâmetros**
  - Número de camadas ocultas;
  - Número de neurônios de cada camada.



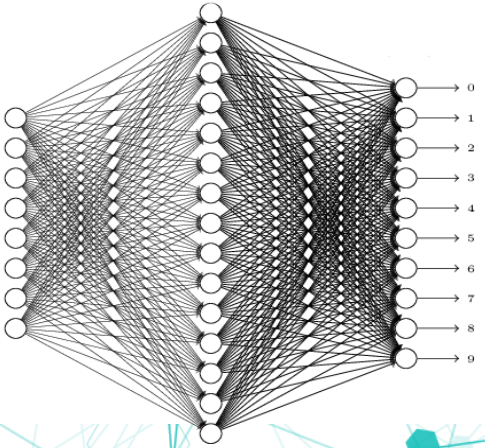
Definição dos hiperparâmetros de uma rede

- Há outra classe de parâmetros definida antes do processo de treinamento → **hiperparâmetros**
  - Inicialização dos pesos.



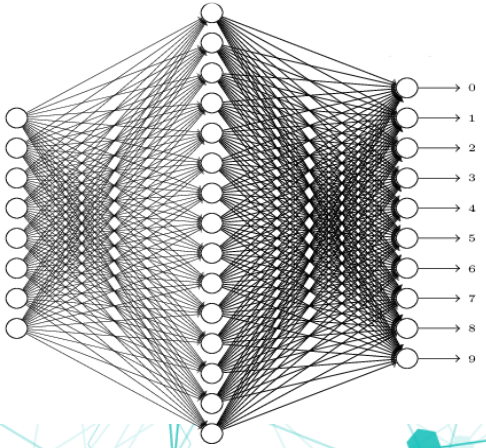
Definição dos hiperparâmetros de uma rede

- Há outra classe de parâmetros definida antes do processo de treinamento → **hiperparâmetros**
  - Taxa de aprendizado.



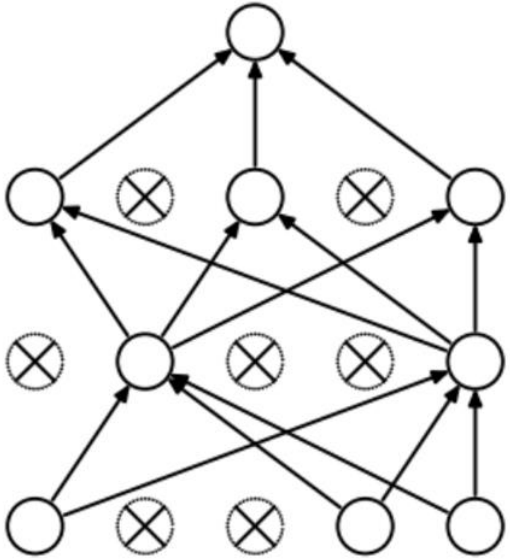
Definição dos hiperparâmetros de uma rede

- Há outra classe de parâmetros definida antes do processo de treinamento → **hiperparâmetros**
  - Número de épocas.



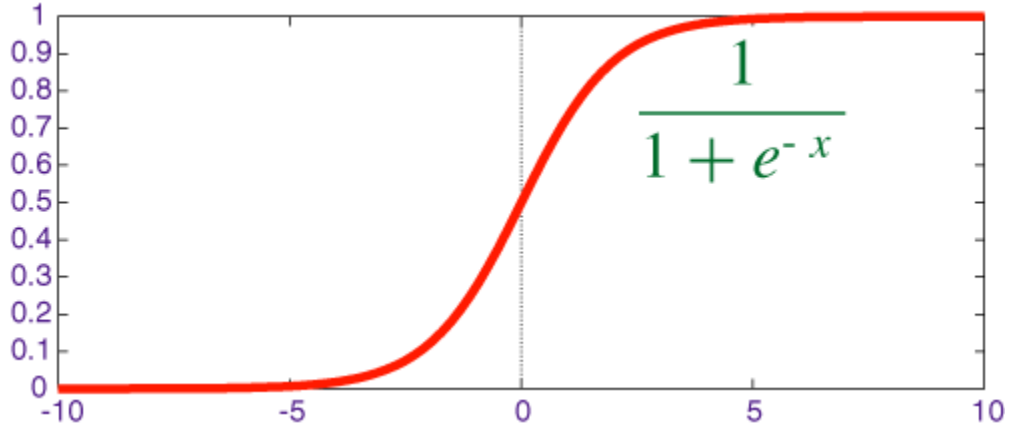
Definição dos hiperparâmetros de uma rede

- Há outra classe de parâmetros definida antes do processo de treinamento → **hiperparâmetros**
  - Probabilidade de inativação de neurônios no dropout.



Definição dos hiperparâmetros de uma rede

- Há outra classe de parâmetros definida antes do processo de treinamento → **hiperparâmetros**
  - Função de ativação.



Mecanismos de definição

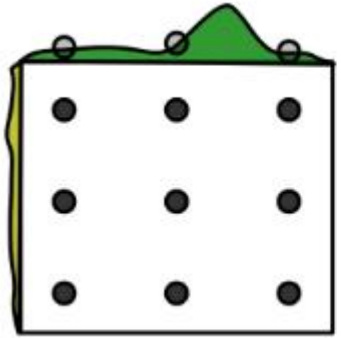
- Pesquisa aleatória (random search) → Testar todas as combinações possíveis de hiperparâmetros
  - Conjunto fixo para parâmetros discretos.
  - Conjunto infinito para parâmetros contínuos.
  - Ideal para

Mecanismos de definição

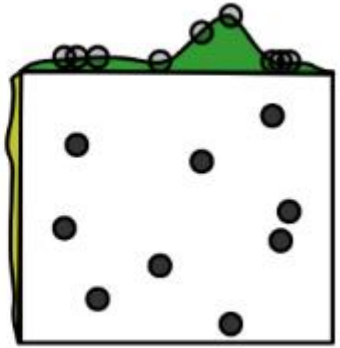
- Pesquisa em grade (grid search) → Testar um subconjunto dos hiperparâmetros disponíveis
  - Número de camadas ocultas (1, 2, 3, 4).
  - Número de neurônios em cada camada (5, 10, 15, 20).
  - Taxa de aprendizado (0,01%, 0,1%, 0,5%, 1%).

Mecanismos de definição

Pesquisa em grade



Pesquisa aleatória



Mecanismos de definição

- **Validação cruzada k-fold** → método de avaliação dos hiperparâmetros
  - Consiste na divisão do conjunto de amostras em k partições;
  - Uma partição é utilizada para validação;
  - As outras k-1 são utilizadas como treinamento;
  - Obtém-se a média de cada combinação de partições.

Mecanismos de definição

Para cada conjunto de hiperparâmetros:

    Para cada combinação de partição:

        Separe as partições de treinamento e de validação

        Treine a rede e salve e calcule a perda

    Calcule a perda média

Salve os hiperparâmetros com menor perda média

Conclusão

- ☑ Os hiperparâmetros de uma rede são definidos antes do processo de treinamento.
- ☑ Pesquisa aleatória (random search) e pesquisa em grade (grid search) são formas de definir os parâmetros de uma rede.
- ☑ Validação cruzada k-fold é uma técnica que divide o conjunto de dados em k partições.
- ☑ A validação cruzada k-fold é uma forma de definir os hiperparâmetros de uma rede.

Próxima aula

- Fine Tuning em Redes Neurais.



Aula 5.10. Fine Tuning em Redes Neurais

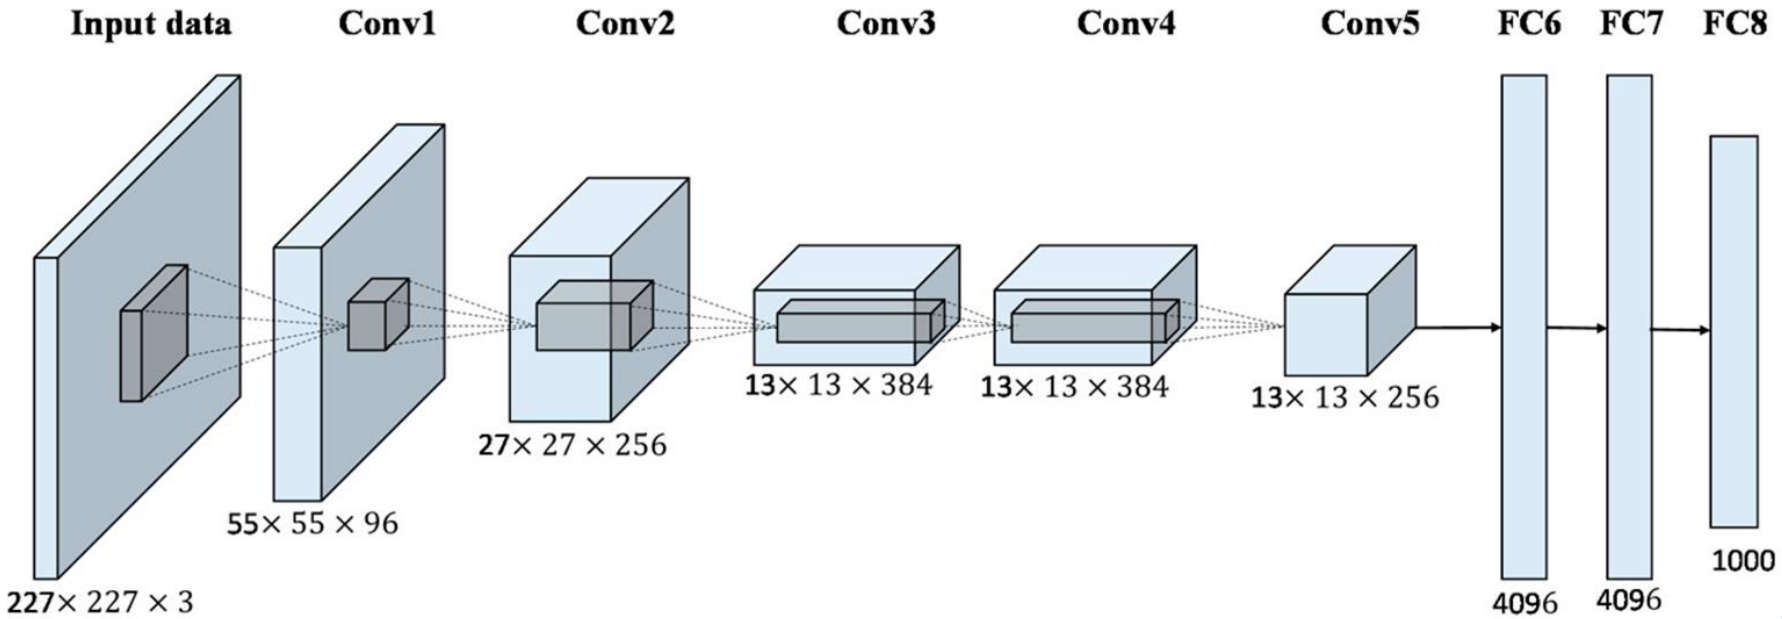


Nesta aula

- O que é o fine-tuning.
- Quando aplicar o fine-tuning.
- Técnicas para aplicar o fine-tuning.

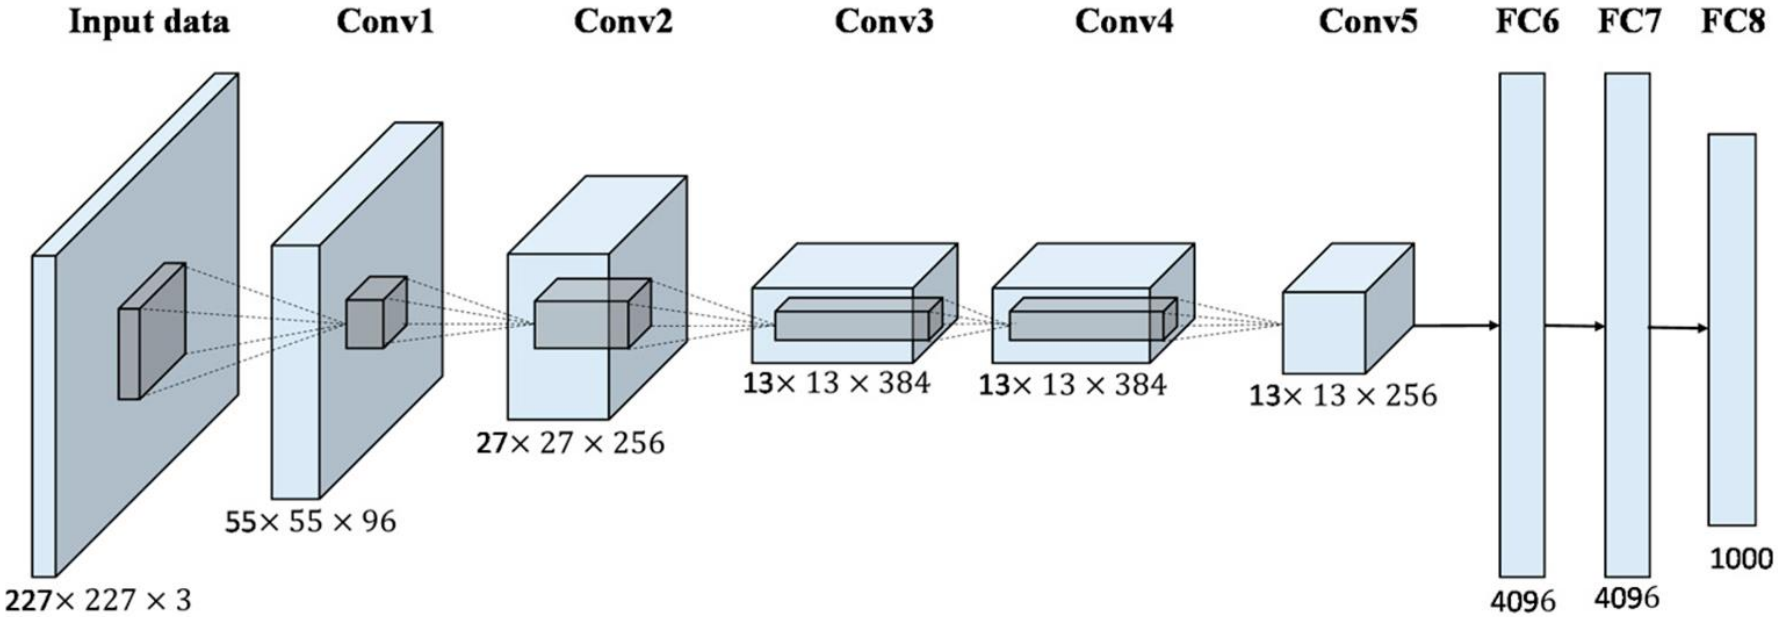
O que é o fine-tuning

- AlexNet → 60 milhões de parâmetros!



O que é o fine-tuning

- Conjunto de treinamento pequeno → overfitting.
- Conjunto de treinamento grande → muito tempo!



O que é o fine-tuning

- **Problema**: como otimizar o tempo de treinamento de uma rede?

O que é o fine-tuning

- Solução: continuar um treinamento já realizado em alguma base de dados grande (ImageNet)!
  - Aplicar o algoritmo de retropropagação na base de dados que se possui.
- Esse processo é conhecido como **fine-tuning**.

Quando aplicar o fine-tuning

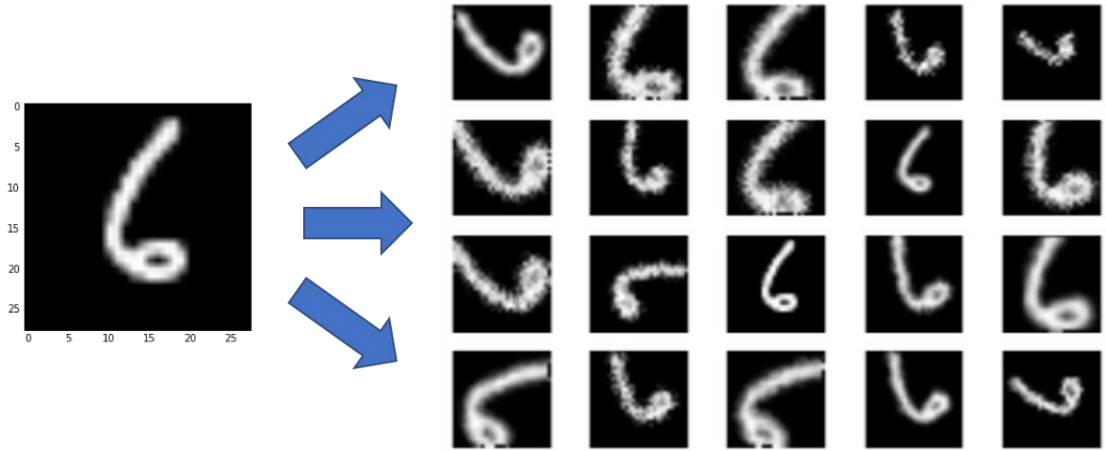
- Quando o conjunto de dados que se possui não é muito diferente de um outro já treinado
  - ImagNet é muito diverso e captura informações universais (curvas, bordas, etc.).
- Não é útil quando seu conjunto de dados é muito diferente (imagens médicas, por exemplo).

Técnicas para aplicar o fine-tuning

- Substituir a última camada, responsável por fazer a classificação.
- Usar uma taxa de aprendizado baixa, uma vez que eles já foram calculados.
- Manter os pesos das primeiras camadas (capturam informações universais).

Técnicas para aplicar o fine-tuning

- **Data augmentation** → técnica para se aumentar um conjunto de dados pequeno
  - Consiste em realizar transformações nos dados.



Conclusão

- ☑ Uma rede com muitos parâmetros pode levar muito tempo para ser treinada (AlexNet possui 60 milhões de parâmetros).
- ☑ Uma estratégia para acelerar o processo é continuar um treinamento já iniciado (fine-tuning).
- ☑ Fine-tuning é indicado quando o conjunto pré-treinado é similar ao conjunto que se possui.
- ☑ Algumas estratégias são usadas (manter as primeiras camadas e utilizar taxa de aprendizado baixa).
- ☑ Data augmentation é uma estratégia utilizada para aumentar o conjunto de dados que se possui.

Próxima aula

- O framework TensorFlow Playground.



Aula 5.11. TensorFlow Playground



Nesta aula

- Frameworks de deep learning.
- Tensorflow playground.

Frameworks de deep learning

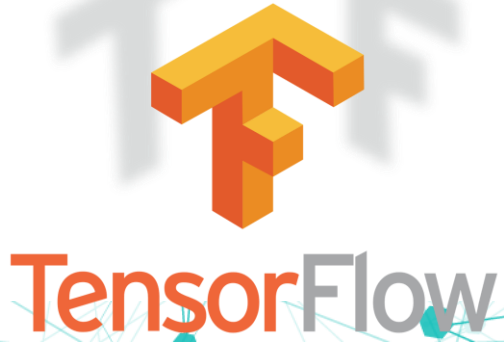
- Como fazer para programarmos uma solução de deep learning?
  - Como criar neurônios?
  - Como definir funções de perda e custo?
  - Como criar camadas?

Frameworks de deep learning

- **Solução** → frameworks
  - Oferecem um nível de abstração maior.
  - Simplificam a utilização de recursos de redes.
  - Facilitam a construção de soluções.

Frameworks de deep learning

- Tensorflow
  - Desenvolvida pela equipe Google Brain.
  - Código aberto.
  - Utilizado por grandes empresas, como Airbus e Twitter.
  - Possui APIs em várias linguagens, como Python, C++ e Java.



Frameworks de deep learning

- Caffe
  - Código aberto.
  - Desenvolvido na universidade da Califórnia.



Frameworks de deep learning

- Torch
  - Código aberto.
  - Desenvolvido em Lua.
  - Utilizado pelo grupo de pesquisa de IA do Facebook.

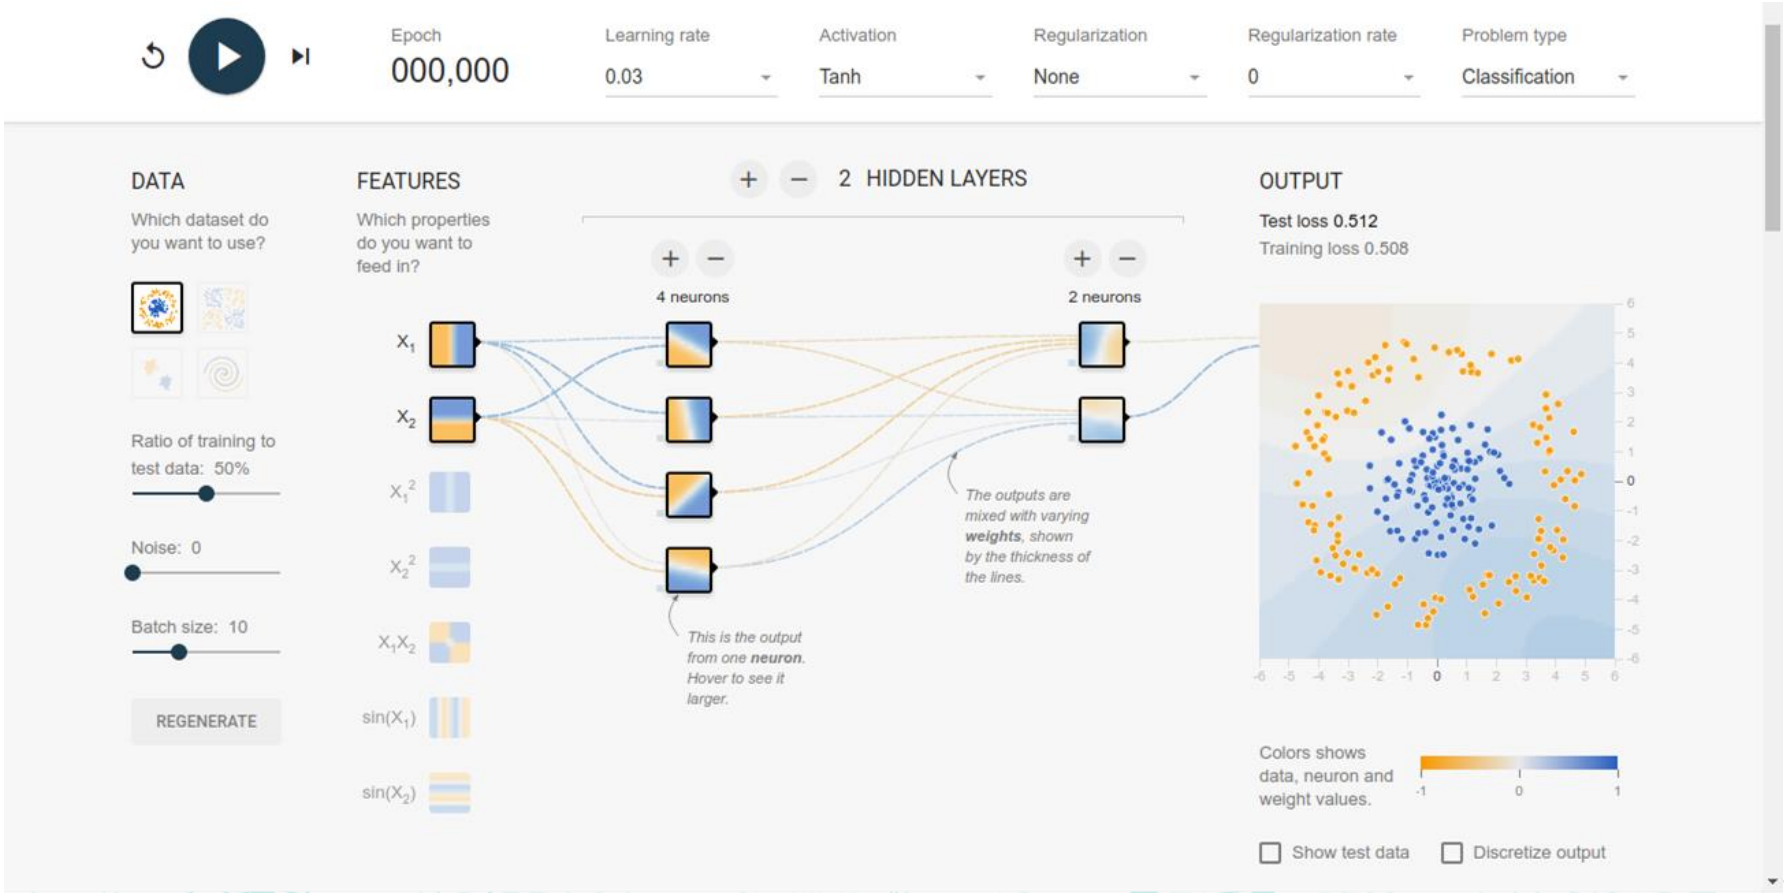


Tensorflow playground

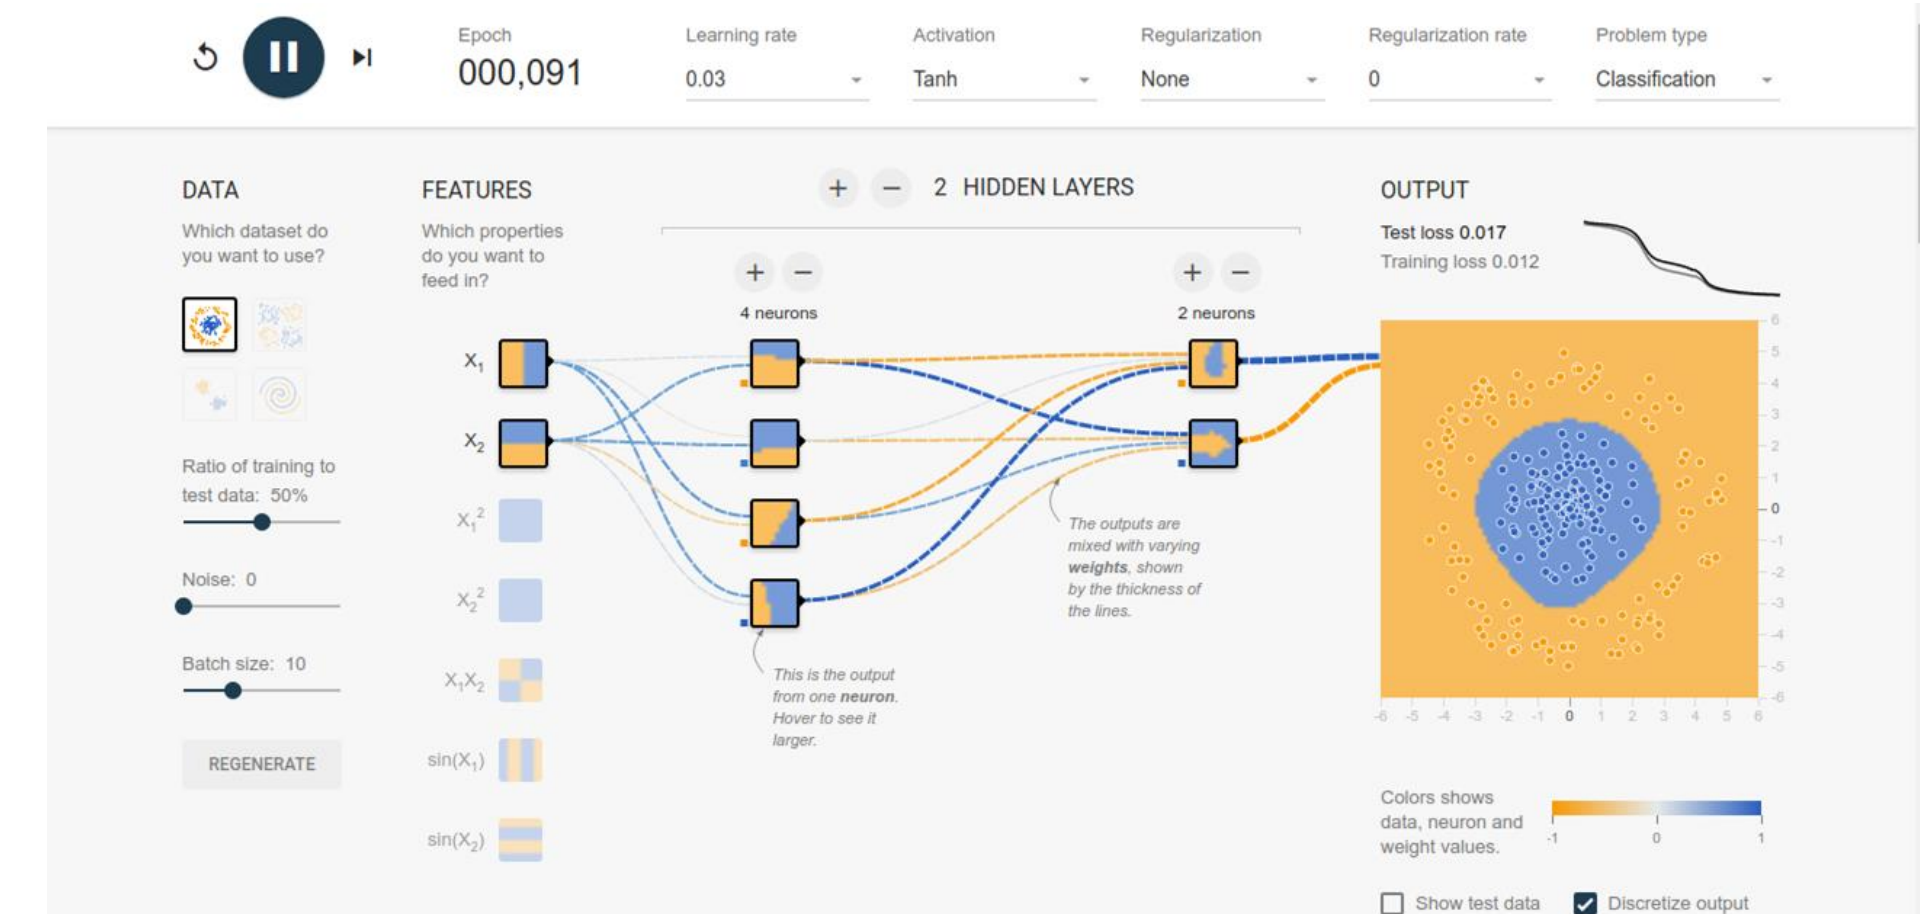
- Tensorflow Playground → ferramenta do Google para entendimento de redes neurais.

https://playground.tensorflow.org

Tensorflow playground



Tensorflow playground



Conclusão

- ☑ Frameworks para deep learning facilitam a implementação de soluções.
- ☑ Frameworks incluem Tensorflow, Torch e Caffee.
- ☑ Tensorflow Playground é uma ferramenta do Google para entendimento de redes neurais.